Priorización de leads inmobiliarios con modelos predictivos

Versión pública anonimizada de la tesis

Angie Flores
Ingeniería Industrial
Universidad del Valle de Guatemala

2026

Nota sobre esta edición

Esta es una adaptación pública para portafolio. Conserva la exposición académica y los resultados agregados del trabajo. Los nombres de empresas, proyectos, campañas y fuentes comerciales se sustituyeron por etiquetas genéricas. Se retiraron figuras originales, capturas, ejemplos empíricos del diccionario y anexos operativos que pudieran revelar información confidencial. No se incluyen bases del CRM, identificadores individuales, modelos entrenados con datos reales ni documentos internos.

El código público también contiene adaptaciones. La demostración utiliza exclusivamente datos y modelos sintéticos: sus resultados no representan el rendimiento histórico de la tesis. Esta edición no sustituye el documento académico original.

Índice general

Resumen **5**

1. Introducción **7**

2. Antecedentes **8**
2.1. Investigación previa en calificación predictiva de leads . . . 8
2.2. Capacidad comercial y priorización bajo restricción . . . 8
2.3. Desbalance de clases y evaluación orientada al beneficio . . . 9
2.4. Segmentación de clientes . . . 9
2.5. Modelado predictivo en el sector inmobiliario . . . 9
2.6. Aporte diferencial del presente trabajo . . . 9

3. Objetivos **11**
3.1. Objetivo General . . . 11
3.2. Objetivos Específicos . . . 11

4. Alcance **12**

5. Justificación **14**

6. Marco teórico **15**
6.1. Analítica de datos aplicada en procesos comerciales . . . 15
6.2. Conjuntos de datos . . . 15
6.3. Inteligencia artificial y aprendizaje automático . . . 15
6.3.1. Entornos para ciencia de datos . . . 16
6.4. Recorrido del cliente y embudo comercial . . . 16
6.5. Calificación y priorización de leads . . . 16
6.6. Tiempo de respuesta y conversión de leads . . . 17
6.7. Modelado predictivo en el sector inmobiliario . . . 17
6.7.1. Modelos analíticos aplicables al proceso comercial . . . 18
6.7.2. Codificación de variables categóricas . . . 19
6.8. El desbalance de clases . . . 19
6.8.1. Estrategias de tratamiento . . . 19
6.9. Evaluación de modelos y definición de éxito . . . 19
6.9.1. Matriz de confusión . . . 19
6.9.2. Exactitud . . . 20
6.9.3. Precisión . . . 20
6.9.4. Sensibilidad . . . 20
6.9.5. Curva ROC y ROC-AUC . . . 20
6.9.6. Curva precisión–sensibilidad y PR-AUC . . . 21
6.9.7. Lift y curvas de ganancia . . . 21
6.10. Métricas secundarias de evaluación . . . 21
6.10.1. Área bajo la curva ROC . . . 21

6.10.2. Brier score . . . 22
6.10.3. Coeficiente de correlación de Matthews . . . 22
6.10.4. Estadístico κ de Cohen . . . 23
6.11. Validación de modelos . . . 23
6.11.1. Fuga de información . . . 23
6.11.2. Interpretación del modelo . . . 23
6.12. Segmentación mediante análisis de conglomerados . . . 24
6.12.1. El algoritmo K-Means . . . 24
6.12.2. Escalamiento y ponderación . . . 24
6.12.3. Evaluación de la calidad del agrupamiento . . . 24
6.12.4. Validación externa mediante una variable no utilizada . . . 24
6.13. Pruebas estadísticas empleadas . . . 25
6.14. Simulación de Monte Carlo . . . 25
6.15. Gestión por procesos y notación BPMN . . . 25
6.16. Metodología CRISP-DM . . . 25

7. Metodología **27**
7.1. Entendimiento del negocio . . . 27
7.1.1. Mapeo del proceso comercial . . . 27
7.2. Entendimiento de los datos . . . 28
7.3. Preparación de los datos . . . 28
7.3.1. Tratamiento diferenciado de la ausencia de datos . . . 28
7.3.2. Definición de universos mediante el embudo de completitud . . . 28
7.3.3. Construcción de variables derivadas . . . 29
7.4. Estrategia de modelado e iteración experimental . . . 29
7.4.1. Segmentación de clientes (K-Means) . . . 29
7.4.2. Modelo predictivo de conversión . . . 30
7.4.3. Decisiones metodológicas críticas . . . 30
7.5. Estrategia de evaluación técnica y operacional . . . 30
7.5.1. Evaluación técnica analítica . . . 30
7.5.2. Evaluación operativa mediante simulación de Monte Carlo . . . 31
7.6. Implementación y transferencia de conocimiento . . . 32
7.6.1. Restricciones estructurales del diseño técnico . . . 32
7.6.2. Marco documental para la transferencia operativa . . . 32

8. Resultados y Discusión **34**
8.1. Proceso comercial y gestión de leads . . . 34
8.1.1. Identificación de puntos críticos y hallazgos del proceso . . . 35
8.1.2. Embudo comercial . . . 36
8.1.3. Razones de pérdida registradas . . . 36
8.1.4. Disponibilidad de información . . . 37
8.2. Estructuración del conjunto de datos . . . 38
8.2.1. Consolidación del historial . . . 38
8.2.2. Disponibilidad de variables para el modelado . . . 38
8.2.3. Completitud de la información . . . 40
8.2.4. Universos de modelado . . . 40
8.2.5. Análisis exploratorio . . . 41
8.3. Modelo predictivo y segmentación de leads . . . 43
8.3.1. Modelo predictivo de conversión . . . 43
8.3.2. Segmentación de leads . . . 45
8.4. Evaluación del modelo predictivo . . . 47
8.4.1. Discriminación y calibración . . . 47
8.4.2. Importancia de variables . . . 48
8.4.3. Comparación con selección aleatoria . . . 49

8.5. Implementación en Power BI 51

9. Conclusiones **52**

10. Recomendaciones **53**

Referencias **55**

A. Modelo BPMN del proceso comercial **59**

B. Diccionario de variables **60**

C. Embudo de completitud de una iteración previa de leads calificados **65**

D. Detalle de la ingeniería de variables **66**

E. Evidencia complementaria del análisis exploratorio **67**
E.1. Evolución temporal del volumen y de la conversión 67
E.2. Campañas publicitarias con comportamiento atípico 67
E.3. Diferencias demográficas de menor magnitud 68
E.3.1. Sexo 68
E.3.2. Estado civil y presencia de hijos 68
E.3.3. Tamaño del núcleo familiar 68

F. Registro de modelos evaluados **70**
F.1. Segmentación de leads (K-Means) — 323 modelos 70
F.2. Modelo predictivo de conversión — 489 modelos 72

G. Comparación entre algoritmos y estrategias de balanceo **75**
G.1. Comparación entre algoritmos 75
G.2. Estrategias de tratamiento del desbalance 75

H. Caracterización detallada de la segmentación **77**
H.1. Configuración y calidad interna 77
H.2. Representación visual de los segmentos 77
H.3. Poder discriminante de las variables 78
H.4. Tamaño y composición de los segmentos 78

I. Coeficientes principales del modelo predictivo final **80**

J. Material operativo omitido en la edición pública **82**

Resumen

Los proyectos residenciales de empresas desarrolladoras en la Ciudad de Guatemala generan un volumen de leads que excede la capacidad de atención de la fuerza de ventas, sin un criterio estructurado que oriente sobre a quién contactar primero. Bajo una selección aleatoria, se necesita contactar, en promedio, a 31 leads para obtener una conversión, cifra que refleja el esfuerzo comercial asociado a una atención sin priorización.

Este trabajo desarrolló un sistema de priorización comercial compuesto por tres elementos: un modelo que estima la probabilidad de conversión de cada lead, una segmentación que perfila a los clientes potenciales y un tablero en Power BI que presenta ambos resultados al equipo comercial. El proceso de ventas se documentó previamente mediante notación BPMN para identificar el punto del flujo en el que debía incorporarse la priorización.

El resultado central es una reducción sustancial del esfuerzo comercial por conversión. Al priorizar la cartera mediante el modelo, el 5 % con mayor probabilidad estimada concentra 223 de las 739 conversiones históricas del universo analizado, lo que equivale a 5 leads contactados por conversión obtenida, frente a los 31 de la selección aleatoria. En un punto de operación más amplio, el modelo recupera el 70 % de las conversiones reales al priorizar menos de un tercio de la cartera. La segmentación identificó seis perfiles de clientes, dos de los cuales presentan una tasa de conversión significativamente superior al promedio y comparten una misma motivación de compra.

El sistema reordena la cartera sin garantizar la identificación de compradores individuales; por lo tanto, se recomienda usarlo como criterio de orden de atención, reforzar el registro de las variables clave y validar su impacto mediante una prueba controlada antes de su adopción generalizada.

Abstract

Residential projects developed by homebuilders in Guatemala City generate a volume of leads that exceeds the sales team's capacity to attend to them, with no structured criterion for deciding whom to contact first. Under random selection, an average of 31 leads must be contacted to obtain one conversion, a figure that reflects the cost of operating without prioritization.

This work developed a commercial prioritization system built from three components: a model that estimates each lead's probability of conversion, a segmentation that profiles prospective customers, and a Power BI dashboard that delivers both outputs to the sales team. The sales process was first documented using BPMN notation to locate the exact point in the workflow where prioritization needed to be inserted.

The central result is a substantial reduction in commercial effort per conversion. When prioritized by the model, the top 5 % of the portfolio by estimated probability captures 223 of the 739 historical conversions in the analyzed universe, equivalent to 5 leads contacted per conversion obtained, compared to 31 under random selection. At a broader operating point, the model recovers 70 % of actual conversions while contacting less than a third of the portfolio. The segmentation identified six customer profiles, two of which convert at a rate significantly above average and share the same stated purchase motivation.

The finding with the greatest practical implication is that a lead's acquisition channel predicts conversion better than its demographic profile, suggesting that commercial effort should be reoriented toward the contact's origin. The system reorders the portfolio without guaranteeing individual buyers; it is therefore recommended as a criterion for ordering outreach, alongside strengthening the recording of channel variables and validating its impact through a controlled trial before a generalized adoption.

Capítulo 1

Introducción

Los datos se han convertido en un activo valioso para las organizaciones que continuamente buscan maneras de mejorar la toma de decisiones y la eficiencia operativa. Sin embargo, a menudo se subutilizan en los procesos comerciales, donde los equipos priorizan el contacto directo con *leads* sobre el análisis de su comportamiento a lo largo del ciclo de ventas. El presente proyecto propone un cambio hacia un enfoque basado en analítica de datos, mediante el cual los equipos comerciales pueden utilizar la información disponible para comprender mejor los patrones de comportamiento de los clientes y orientar sus decisiones. En el contexto de las empresas desarrolladoras inmobiliarias en la Ciudad de Guatemala, los proyectos residenciales generan un alto volumen de contactos, lo que implica para los asesores comerciales el reto de gestionar el tiempo y los recursos disponibles entre múltiples clientes potenciales. Tratar todos los *leads* de la misma manera no necesariamente conduce a los mismos resultados, especialmente en el sector inmobiliario, donde los ciclos de compra suelen ser largos e involucran múltiples interacciones previas a la conversión. Sin una guía analítica para establecer un orden de atención, los esfuerzos comerciales pueden resultar ineficientes.

El objetivo del proyecto fue desarrollar y validar modelos predictivos aplicados a la gestión comercial de proyectos residenciales de vivienda en la Ciudad de Guatemala. El enfoque principal se centró en actividades de mercadeo y gestión comercial de vivienda, para las cuales se desarrolló un modelo de priorización de *leads* basado en la probabilidad de conversión, complementado con un análisis de segmentación mediante *k-means* para identificar perfiles de clientes. Este enfoque proporciona un criterio basado en datos para dirigir los recursos disponibles hacia las oportunidades con mayor potencial. Más allá del análisis predictivo, el proyecto incluyó el mapeo del proceso comercial mediante notación BPMN y la identificación de la etapa en la que debía incorporarse el sistema desarrollado. El análisis empírico se realizó con información de seis proyectos residenciales específicos, utilizados como caso de aplicación.

Los resultados obtenidos respaldan la viabilidad del enfoque propuesto como mecanismo para ordenar la cartera comercial. El modelo final logra recuperar el 70 % de las conversiones reales al concentrar la gestión en menos de un tercio de la cartera y, en el primer decil del ordenamiento, reúne cuatro veces más conversiones que una selección realizada al azar. Su principal aporte, por tanto, no radica en determinar de forma individual qué prospectos se convertirán, sino en establecer una secuencia de atención que concentre los esfuerzos en aquellos con mayor probabilidad de hacerlo. En este contexto, la precisión obtenida en el punto de operación fue del 7.9 %, lo que refleja también la baja frecuencia de conversiones en los datos analizados. Asimismo, las características relacionadas con el origen del *lead* aportaron mayor capacidad predictiva que las variables demográficas, lo que evidencia la relevancia del contexto de captación para ordenar la cartera.

El documento se organiza de la siguiente manera: los capítulos iniciales sitúan el trabajo en relación con la investigación previa, establecen los objetivos, el alcance y las limitaciones, exponen la justificación y desarrollan el marco conceptual que sustenta el análisis. El capítulo de metodología describe la aplicación de las seis fases del marco CRISP-DM. A continuación, el capítulo de resultados presenta los hallazgos del análisis exploratorio, la segmentación, el modelo predictivo y su evaluación operativa. El capítulo de discusión los interpreta y examina sus implicaciones operativas y las limitaciones del estudio. Finalmente, se presentan las conclusiones y recomendaciones, mientras que los anexos documentan la fórmula completa del modelo y la trazabilidad de las cifras reportadas.

Capítulo 2

Antecedentes

2.1. Investigación previa en calificación predictiva de leads

La sustitución de sistemas de calificación basados en reglas por modelos ajustados sobre el historial de conversión tiene antecedentes consolidados. González-Flores, Rubiano-Moreno, y Sosa-Gómez (2025) documentan un caso en el que un esquema tradicional de lead scoring, basado en asignación manual de valores por parte de marketing y ventas, fue reemplazado por un modelo predictivo seleccionado tras comparar quince algoritmos de clasificación, logrando mejoras sustanciales en la capacidad de distinguir leads de alta y baja calidad. Su diagnóstico de que los métodos manuales tienden a ser arbitrarios y menos precisos coincide con el del proceso comercial analizado en este trabajo.

En la literatura de *lead scoring* se han comparado algoritmos como la regresión logística y los métodos de ensamble Nygård y Mezei (2020), con resultados que dependen de las características del conjunto de datos, la definición del objetivo y las métricas de evaluación empleadas. Tan, Lim, Lim, Tan, y Husaini (2024) obtienen resultados equivalentes en el sector educativo, apoyándose en variables de comportamiento digital como la duración de visita a las páginas.

La revisión de Wu, Andreev, y Benyoucef (2024) sobre el estado de los modelos de calificación y su impacto en el desempeño comercial matiza estos resultados: la ganancia documentada depende menos del algoritmo seleccionado que de la calidad de las variables disponibles y de la integración efectiva del modelo en el flujo de trabajo del equipo de ventas. Esta observación es consistente con Ahearne, Hughes, y Schillewaert (2007), quienes muestran que el impacto de los sistemas CRM sobre la efectividad comercial se materializa únicamente cuando los representantes incorporan la herramienta en su rutina.

2.2. Capacidad comercial y priorización bajo restricción

Sabnis, Chatterjee, Grewal, y Lilien (2013) documentan el fenómeno del *agujero negro de los leads*: la fracción de oportunidades generadas por mercadeo que no son perseguidos debido a la capacidad limitada del equipo comercial. Su aporte al presente trabajo es conceptual: establece que el problema no es de generación sino de asignación, lo que justifica formular la evaluación en términos de conversiones capturadas bajo una restricción de capacidad, y no en términos de exactitud agregada.

Los estudios sobre el tiempo de respuesta a leads web muestran que las probabilidades de contacto y calificación disminuyen a medida que aumenta el tiempo transcurrido desde la solicitud. Oldroyd, McElheran, y Elkington (2011) encuentran que intentar contactar a un prospecto dentro de la primera hora se asocia con una mayor probabilidad de calificación que hacerlo después de ese lapso. En consecuencia, bajo una capacidad limitada de atención comercial, la oportunidad de respuesta debe considerarse junto con la probabilidad de conversión al definir el orden de priorización.

Ohiomah, Andreev, Benyoucef, y Hood (2019) aportan evidencia empírica de que el uso de sistemas de gestión de leads se asocia con un mejor desempeño en ventas internas, mediante una mayor intensidad de seguimiento de leads, una venta más adaptativa y el fortalecimiento de competencias técnicas y de venta. Este hallazgo sustenta la decisión de entregar la priorización como un artefacto operativo integrado al proceso

de gestión de leads, y no únicamente como un reporte analítico independiente.

2.3. Desbalance de clases y evaluación orientada al beneficio

En problemas de clasificación binaria con clase minoritaria muy escasa, Verbeke, Dejaeger, Martens, Hur, y Baesens (2012) desarrollan un enfoque explícitamente orientado al beneficio, basado en el beneficio máximo potencial de intervenir sobre una fracción óptima de clientes, y muestran que seleccionar modelos mediante métricas exclusivamente estadísticas puede conducir a decisiones subóptimas. Burez y Van den Poel (2009) examinan el tratamiento del desbalance de clases empleando AUC y *lift*, y encuentran que el submuestreo avanzado CUBE no mejora el desempeño predictivo, lo que indica que las estrategias de remuestreo no garantizan mejoras en métricas de discriminación u ordenamiento. De forma consistente, en el presente trabajo SMOTE no mejoró las métricas de ordenamiento y deterioró la calibración; este resultado debe interpretarse como un hallazgo específico de los datos y modelos analizados, no como una consecuencia general del remuestreo.

En una línea complementaria, Devriendt, Moldovan, y Verbeke (2018) revisan el modelado de elevación (*uplift modeling*), cuyo objetivo es estimar el efecto incremental de una intervención sobre un resultado, en lugar de predecir únicamente la probabilidad de dicho resultado. Este enfoque quedó fuera del alcance del presente trabajo, pues requiere datos que permitan identificar el efecto de una acción comercial frente a una condición de comparación —idealmente mediante un diseño experimental aleatorizado—. No obstante, constituye una extensión pertinente si se dispone de intervenciones comerciales observables y datos adecuados para estimar sus efectos causales.

2.4. Segmentación de clientes

La segmentación de clientes mediante técnicas de agrupamiento constituye una práctica consolidada en investigación de mercados y analítica comercial. (Kaufman y Rousseeuw, 1990) presentan fundamentos y métodos clásicos de análisis de conglomerados. Estas técnicas pueden emplearse, entre otros fines, para apoyar la definición de territorios comerciales, la asignación de carteras y la identificación de perfiles de clientes, siempre que se valide empíricamente la utilidad operativa de los segmentos obtenidos.

En la base de datos utilizada en este trabajo, varios atributos relevantes, por ejemplo, motivación de compra, estado civil y tipología de unidad de interés, son categóricos. Esta característica exige precaución al utilizar K-Means estándar, ya que este algoritmo se basa en centroides y distancias euclídeas, y por tanto está definido de forma natural para variables numéricas. Para datos categóricos o mixtos, pueden emplearse codificaciones adecuadas junto con criterios de escalamiento y ponderación, o bien métodos específicamente diseñados para este tipo de información, como K-prototypes o KAMILA. La estrategia adoptada en este trabajo debe especificar la codificación aplicada, la métrica de distancia y el criterio usado para fijar los pesos, a fin de evitar que el número de categorías o la escala de un bloque de variables domine la segmentación.

2.5. Modelado predictivo en el sector inmobiliario

La investigación aplicada al sector inmobiliario ha documentado que la combinación de juicio experto con modelos analíticos habilita la identificación de oportunidades no evidentes (Palmer, 2025). La complejidad particular del sector, tales como ciclos de decisión largos, desembolso elevado y participación de varias personas en la decisión, reduce la eficacia de los enfoques basados exclusivamente en reglas estáticas.

2.6. Aporte diferencial del presente trabajo

Respecto a los antecedentes revisados, este trabajo aporta cuatro elementos:

1. **Tratamiento de la ausencia de datos como señal.** La literatura consultada asume habitualmente conjuntos de datos con completitud razonable. El contexto de este trabajo: un CRM donde el perfil se completa progresivamente durante la calificación, obliga a un tratamiento distinto, en el que la

propia estructura de ausencia se incorpora como información predictiva en lugar de eliminarse mediante imputación.

2. **Evaluación contra una distribución de referencia explícita.** En lugar de reportar únicamente métricas de discriminación, el desempeño se contrasta contra la distribución completa del resultado que produciría la ausencia de priorización, obtenida por simulación y verificada analíticamente contra la distribución hipergeométrica exacta.

3. **Restricción deliberada de generalización.** La exclusión de la identidad del proyecto del conjunto de predictores, con cuantificación explícita del costo estadístico que implica, responde al requisito de aplicabilidad a proyectos residenciales futuros.

4. **Integración del análisis de procesos con el modelo predictivo.** El modelado BPMN del proceso comercial no se limita a documentar el estado actual: determina el punto de inserción de la intervención analítica y define el momento en que la predicción debe emitirse, lo que a su vez fija qué variables pueden considerarse disponibles y cuáles constituyen fuga de información.

5. **Contextualización en el mercado inmobiliario guatemalteco.** El trabajo aporta evidencia empírica obtenida en el contexto de empresas desarrolladoras de vivienda en la Ciudad de Guatemala, a partir de datos de proyectos residenciales locales. Esta contextualización permite evaluar el comportamiento del enfoque de priorización bajo las características propias del entorno comercial analizado, en lugar de asumir directamente que los resultados obtenidos en otros contextos son transferibles al mercado guatemalteco.

Capítulo 3

Objetivos

3.1. Objetivo General

Desarrollar y validar modelos predictivos para la priorización y conversión de leads aplicados al proceso comercial de proyectos residenciales de empresas desarrolladoras de vivienda en la Ciudad de Guatemala.

3.2. Objetivos Específicos

- Analizar el proceso de administración de leads dentro del embudo comercial mediante la identificación de sus etapas y dinámicas operativas.
- Estructurar el conjunto de datos mediante procesos de limpieza, integración y análisis exploratorio para habilitar su utilización en modelos analíticos de predicción.
- Desarrollar modelos predictivos de priorización de leads utilizando técnicas de ciencia de datos que estimen la probabilidad de conversión dentro del embudo comercial.
- Evaluar el desempeño de los modelos desarrollados utilizando métricas de validación que aseguren un ajuste idóneo para la toma de decisiones en el área comercial.

Capítulo 4

Alcance

El presente proyecto se enfocó en la etapa del proceso comercial donde los leads son activamente gestionados y priorizados, utilizando la etapa de reserva como punto de corte para evaluar los resultados de conversión. Dentro de este límite, el trabajo se centró en establecer criterios estructurados y basados en datos que sirvan de apoyo a la manera en que los leads son evaluados y priorizados en proyectos residenciales de vivienda de empresas desarrolladoras en la Ciudad de Guatemala. De esta manera, el alcance del estudio se delimita a una fase específica del embudo comercial, sin extenderse a etapas posteriores del proceso de venta.

Desde una perspectiva de viabilidad, el proyecto dependió del acceso a datos comerciales existentes y del conocimiento de los procesos internos vinculados a proyectos residenciales específicos. Los recursos requeridos fueron primordialmente digitales, incluyendo conjuntos de datos derivados de sistemas CRM. Estos recursos estuvieron disponibles a través de la coordinación con la entidad que facilitó la información, lo que permitió realizar el análisis sin necesidad de infraestructura adicional ni de sistemas nuevos de recolección de datos. Las fuentes principales incluyeron datos internos, documentación del proceso comercial y hallazgos recuperados de las partes interesadas involucradas en la gestión de leads, lo que permitió una comprensión fundamentada de cómo se toman actualmente las decisiones comerciales. Los recursos secundarios consistieron en literatura académica, reportes de la industria e investigación previa en calificación de leads, modelado predictivo y optimización del proceso comercial, que proveyeron la base conceptual y metodológica para el análisis.

En términos de tiempo, el proyecto se estructuró para alinearse con el calendario académico, asignando tiempo a cada una de las fases, desde el entendimiento del negocio hasta el desarrollo del modelo y la propuesta de implementación. Esta planificación permitió que cada etapa contara con espacio suficiente para su desarrollo y revisión, y que el avance del trabajo se monitoreara de manera ordenada y consistente.

El estudio está sujeto a diversas limitaciones, varias de las cuales se materializaron durante el desarrollo y condicionaron los resultados obtenidos.

En primer lugar, la disponibilidad y calidad de los datos alteró el alcance del análisis. La ausencia de información resultó ser masiva y estructurada: las variables de perfil demográfico presentan porcentajes de valores faltantes que alcanzan el 93.5 %, dado que no se registran en el primer contacto sino conforme avanza la calificación del lead. Esta característica obligó a redefinir el universo de modelado y a tratar la ausencia como categoría informativa en lugar de imputarla. Adicionalmente, se identificaron trece columnas con fuga de información, campos que solo se completan una vez cerrada la venta, cuya remoción redujo sustancialmente el desempeño aparente de las primeras versiones del modelo.

En segundo lugar, el proyecto no se extendió más allá de la etapa de reserva, excluyendo procesos posteriores tales como la formalización del contrato, la promesa de compra o el análisis de crédito.

En tercer lugar, aunque el estudio se plantea desde una perspectiva metodológica aplicable al contexto de las empresas desarrolladoras inmobiliarias en la Ciudad de Guatemala, el análisis empírico se desarrolló con información correspondiente a seis proyectos residenciales específicos, por lo que los hallazgos deben interpretarse dentro de ese alcance. Para mitigar parcialmente esta limitación, la identidad del proyecto se excluyó deliberadamente del conjunto de predictores, con un costo estadístico cuantificado de aproximadamente 5 % en el desempeño, a cambio de que el modelo sea aplicable a proyectos residenciales nuevos.

En cuarto lugar, los modelos se desarrollaron en un entorno analítico controlado y no fueron implementados en sistemas en producción, lo cual restringe la capacidad de medir el impacto en tiempo real. Todos los

resultados provienen de validación cruzada sobre datos históricos: no se dispuso de una ventana temporal posterior ni de una prueba controlada que permitiera comparar el resultado comercial con y sin priorización. La ganancia reportada es, por lo tanto, una estimación retrospectiva de la calidad del ordenamiento y no una medición de impacto en ventas.

Finalmente, el modelo reordena la cartera comercial pero no identifica compradores con certeza. Esta precisión delimita el tipo de decisión que el modelo puede sostener.

En cuanto al uso de los datos, el proyecto se condujo bajo autorización para trabajar con información real con propósitos académicos. Cualquier dato sensible se manejó bajo acuerdos de confidencialidad y los resultados se presentan de manera que no expongan información personal identificable ni detalles comerciales sensibles. Adicionalmente, aunque las variables de sexo y estado civil se emplearon con finalidad descriptiva en el perfilamiento de segmentos, se establece explícitamente que no deben utilizarse como criterio de asignación de esfuerzo comercial.

Capítulo 5

Justificación

En el sector inmobiliario, el proceso comercial involucra manejar una amplia cantidad de *leads* simultáneamente. Sin embargo, no todos los *leads* muestran el mismo nivel de interés, intención de compra o probabilidad de conversión. Asimismo, no todos requieren el mismo nivel de seguimiento. En escenarios donde no se dispone de herramientas analíticas, las decisiones comerciales pueden basarse, en gran parte, en la intuición, sin un proceso de priorización establecido. Como consecuencia, la priorización de *leads* puede volverse inconsistente, lo que puede concentrar tiempo y recursos en *leads* con una baja probabilidad de conversión, mientras que otras oportunidades de alto valor permanecen desatendidas. Adicionalmente, la generación de *leads* es inherentemente compleja, ya que resulta difícil identificar la influencia de ciertas variables en el comportamiento del cliente sin un análisis sistemático.

Bajo esta premisa, los modelos de análisis de datos brindan una oportunidad para comprender patrones en el comportamiento de los *leads*. Al analizar datos históricos, es posible identificar las características asociadas con mayores probabilidades de conversión. El desarrollo de modelos analíticos puede apoyar la toma de decisiones en el proceso comercial, lo que permite que las empresas desarrolladoras inmobiliarias de la Ciudad de Guatemala prioricen *leads* de manera más eficiente y optimicen dicho proceso.

En este contexto, el problema no requiere únicamente la aplicación de modelos analíticos, sino también la comprensión del proceso comercial como un sistema integrado: un conjunto de actividades, actores, flujos e interacciones operacionales. Mediante el análisis de procesos, es posible identificar ineficiencias y puntos críticos en el embudo comercial, así como determinar en qué etapa del proceso resulta viable la integración de modelos analíticos para apoyar la toma de decisiones. Esta determinación es relevante, pues el punto del flujo en el que se emite la predicción define qué información está efectivamente disponible en ese momento y, por lo tanto, qué variables pueden utilizarse legítimamente como predictores y cuáles constituyen fuga de información. Además, la implementación y el desarrollo de soluciones analíticas requieren un enfoque de gestión de proyectos que integre la definición del problema, la delimitación del alcance, la planificación y la ejecución de manera sistemática y organizada.

Por estos motivos, el proyecto constituye una aplicación práctica de las competencias de Ingeniería Industrial en un contexto real del sector inmobiliario, al combinar técnicas analíticas, una ejecución estructurada del proyecto y el análisis del proceso con el fin de generar un resultado tangible y metodológicamente defendible. Aunque el análisis se centra en seis proyectos residenciales específicos, la propuesta busca que sus hallazgos y su enfoque metodológico puedan discutirse dentro del contexto más amplio de las empresas desarrolladoras inmobiliarias de la Ciudad de Guatemala.

Capítulo 6

Marco teórico

6.1. Analítica de datos aplicada en procesos comerciales

La analítica aplicada a procesos comerciales y de mercadeo permite a las organizaciones explotar los datos históricos de sus clientes con el fin de entender patrones de comportamiento y anticipar resultados. Los equipos comerciales que utilizan modelos analíticos para examinar interacciones y datos transaccionales pueden identificar oportunidades de manera más precisa y reducir el tiempo invertido en clientes con bajo potencial (Smith, Stöber, y Ulrich, 2020; Bykowsky, Devignes, Cruz, Valdivieso, y Torres, 2025). Estas iniciativas extraen variables de sistemas de CRM, redes sociales y campañas digitales para alimentar algoritmos capaces de estimar la probabilidad de compra.

La adopción de tecnología de apoyo a la fuerza de ventas no produce beneficios de manera automática. Ahearne y cols. (2007) muestran que el impacto de los sistemas basados en CRM sobre la efectividad comercial depende de que los representantes integren la herramienta en su rutina de trabajo, y no meramente de su disponibilidad. Esta observación resulta determinante para el diseño de la solución del presente trabajo: la utilidad de un modelo predictivo se realiza únicamente si sus resultados llegan al asesor comercial dentro del entorno donde efectivamente toma decisiones.

6.2. Conjuntos de datos

Un conjunto de datos es una recolección estructurada de datos organizados y almacenados para su análisis o procesamiento. Puede contener valores numéricos, texto, imágenes o audio, y construirse a partir de una o de múltiples fuentes. La selección de un conjunto de datos apropiado constituye uno de los primeros pasos para el entrenamiento de modelos de aprendizaje automático (Han, Kamber, y Pei, 2011).

En contextos empresariales, los conjuntos de datos rara vez se diseñan con fines analíticos: provienen de sistemas transaccionales cuyo propósito es operativo. Esto implica que su estructura refleja el proceso que los generó, incluyendo sus inconsistencias, sus campos incompletos y sus cambios de criterio a lo largo del tiempo (Berry y Linoff, 2004; Blattberg, Kim, y Neslin, 2008). La preparación de los datos, en consecuencia, no es una etapa preliminar menor sino una parte sustantiva del trabajo analítico.

6.3. Inteligencia artificial y aprendizaje automático

El aprendizaje automático es la subdisciplina de la inteligencia artificial que permite a los algoritmos discernir patrones a partir de datos de entrenamiento y generar predicciones sobre instancias no observadas, sin necesidad de programar explícitamente cada escenario. Hastie, Tibshirani, y Friedman (2009) señalan que el aprendizaje automático se centra en la construcción de modelos predictivos mediante la captura de regularidades estadísticas en los datos, abarcando métodos supervisados para resultados etiquetados, técnicas no supervisadas para estructuras ocultas y aprendizaje por refuerzo para la toma de decisiones secuenciales.

En el contexto de este trabajo, el aprendizaje automático sustenta dos componentes distintos. El aprendizaje supervisado sustenta el modelo de calificación de leads mediante la estimación de probabilidades de conversión.

El aprendizaje no supervisado sustenta la segmentación de la cartera en perfiles de cliente.

6.3.1. Entornos para ciencia de datos

Entornos de programación

Para transformar datos crudos en hallazgos, los analistas dependen de entornos de programación desarrollados para la ciencia de datos. El entorno analítico empleado en este trabajo fue Python (Python Software Foundation, s.f.) ejecutado en Jupyter Notebook, dado que permite integrar limpieza de datos, modelado, evaluación, interpretación y documentación en un flujo reproducible. Python cuenta con bibliotecas ampliamente utilizadas para análisis y aprendizaje automático, entre ellas `pandas`, `scikit-learn` (Pedregosa y cols., 2011), `imbalanced-learn` y `SHAP`, lo que lo hace adecuado para el desarrollo de modelos predictivos y análisis explicables.

Comunicación de los resultados

Comunicar los hallazgos requiere más que código. La visualización de datos constituye la representación gráfica de información mediante tablas, gráficos y mapas; permite traducir números abstractos en narrativas accesibles a partes interesadas no técnicas (Tableau, s.f.).

Power BI es la plataforma de análisis empresarial que permite conectar, visualizar y compartir datos dentro de una organización. El lienzo final para estos hallazgos son los tableros o *dashboards*: herramientas de visualización y análisis que muestran el estado de indicadores clave en una misma pantalla, con capacidad interactiva para profundizar en los datos subyacentes y aplicar filtros (Hashemi-Pour y Sutner, 2024). A través de ellos, las personas a cargo de la toma de decisiones pueden monitorear el progreso y detectar anomalías con rapidez.

6.4. Recorrido del cliente y embudo comercial

El recorrido del cliente o *customer journey* representa todas las interacciones que un usuario ha tenido con una marca antes, durante y después de la compra. Mapear este recorrido ayuda a descubrir las necesidades del cliente, identificar los puntos de contacto clave y proponer mejoras de diseño (Miller, 2025). Un recorrido típico incluye las etapas de conocimiento, consideración, compra, retención y promoción.

Un *lead* se refiere a una persona o empresa que ha expresado interés en un producto o servicio específico, lo que indica que puede ser un cliente potencial (Salesforce, 2024). No todos los leads son equivalentes: su calidad depende de factores como el presupuesto, la alineación con el producto y el nivel de compromiso. Conforme avanzan por el canal de ventas, aquellos que cumplen ciertas características se convierten en prospectos, entendidos como contactos calificados con mayor probabilidad de conversión.

La progresión desde el conocimiento inicial hasta la compra se conceptualiza como el embudo comercial: el camino que sigue un cliente potencial desde que conoce el producto hasta que lo adquiere, lo que permite monitorear el progreso y eliminar obstáculos (Long Jr., 2023). Segmentar el embudo en etapas ayuda a diagnosticar dónde se pierden los prospectos y a construir intervenciones específicas por etapa. La secuencia de actividades que compone este proceso ha sido formalizada en la literatura de ventas como una progresión de pasos identificables (Moncrief y Marshall, 2005), cuya representación explícita es requisito para determinar en qué punto puede insertarse una intervención analítica.

6.5. Calificación y priorización de leads

Dado que los recursos son limitados, las organizaciones necesitan un método sistemático para priorizar contactos. La calificación de leads o *lead scoring* asigna valores numéricos a los leads basándose en datos demográficos y comportamientos observados, lo que ayuda a los equipos de mercadeo y ventas a identificar qué clientes potenciales tienen mayor probabilidad de convertirse en clientes (Wu y cols., 2024).

Los sistemas tradicionales dependen de reglas heurísticas que clasifican los leads según la experiencia y el juicio personal. González-Flores y cols. (2025) documentan un caso en el que el sistema tradicional se basaba en una matriz de calificación fija que asignaba manualmente puntos a acciones específicas, como

solicitudes de cotización o interacciones por correo electrónico. Este enfoque refleja una lógica basada en reglas, donde la importancia de cada variable es predefinida por juicio experto en lugar de aprenderse de los patrones presentes en los datos. Como resultado, el sistema carecía de flexibilidad para capturar interacciones complejas entre variables y conducía a una priorización arbitraria y subóptima. La alternativa predictiva desarrollada en ese estudio evaluó quince algoritmos de clasificación, y el modelo de mejor desempeño alcanzó una exactitud del 98.39 %.

Es importante advertir que una cifra de exactitud tan elevada debe interpretarse en función de la tasa base del problema estudiado: como se argumenta en la Sección 6.8, en problemas con clase minoritaria escasa la exactitud deja de ser informativa. Las revisiones sistemáticas del área Wu y cols. (2024) coinciden en que el valor de los modelos de calificación reside en su capacidad de ordenar la cartera, más que en su exactitud agregada.

La gestión formal de leads mediante sistemas dedicados se ha asociado, además, con el desempeño comercial. Ohiomah y cols. (2019) hallaron que el uso de sistemas de gestión de leads se asoció con el desempeño de ventas internas mediante variables como la intensidad de seguimiento de leads, la venta adaptativa y las habilidades técnicas y comerciales de los representantes.

6.6. Tiempo de respuesta y conversión de leads

La adopción de canales digitales ha transformado la manera en que las organizaciones adquieren clientes potenciales, permitiendo generar grandes volúmenes de leads en periodos cortos. Aunque esta expansión crea oportunidades, también introduce un reto operativo de asignación de recursos.

El tiempo de respuesta se ha consolidado como uno de los factores más estudiados por su influencia en la conversión. Se refiere al lapso entre el momento en que un prospecto manifiesta interés y el primer intento de la organización por comunicarse con él. Oldroyd y cols. (2011) reportaron que, en su estudio de respuestas a leads generados en línea, contactar dentro de la primera hora se asoció con una mayor probabilidad de calificación que demorar el contacto. Estos resultados se refieren a la calificación de leads y no necesariamente a la conversión final.

Sabnis y cols. (2013) introdujeron el concepto del *agujero negro de los leads comerciales* para describir situaciones en las que los leads generados por mercadeo nunca reciben seguimiento por parte de los representantes de ventas. Sus hallazgos demuestran que la presión de la carga de trabajo y la capacidad limitada del equipo comercial impiden que las compañías aprovechen la totalidad de los leads generados.

Desde la perspectiva de la ingeniería industrial, esta situación constituye un problema de priorización y asignación de recursos bajo restricción de capacidad. Cuando la demanda de atención comercial excede la capacidad instalada, la organización debe determinar cómo distribuir ese recurso escaso para maximizar los resultados. Bajo esas condiciones, tratar a todos los leads de manera equivalente no es una política óptima, especialmente cuando las probabilidades de conversión varían sustancialmente entre prospectos. Esta formulación —y no la de clasificación— es la que fundamenta el diseño de la evaluación operativa del presente trabajo.

6.7. Modelado predictivo en el sector inmobiliario

En el sector inmobiliario, predecir el interés y la conversión de los prospectos resulta más complejo que en otras industrias debido a factores económicos, emocionales y contextuales. Esta complejidad reduce la eficacia de los enfoques que dependen únicamente de reglas estáticas o de la intuición comercial. En aplicaciones inmobiliarias, el conocimiento del dominio y las herramientas analíticas pueden complementar la identificación y priorización de oportunidades, siempre que los datos disponibles y el proceso comercial permitan su uso operativo.

En la literatura de *lead scoring* se han comparado algoritmos como la regresión logística y los métodos de ensamble (Nygård y Mezei, 2020), con resultados que dependen de las características del conjunto de datos, la definición del objetivo y las métricas de evaluación empleadas. Por su parte, Tan y cols. (2024) implementaron un modelo de *random forest* para calificación de leads en el sector educativo, alcanzando un 89.46 % de exactitud mediante variables como la duración de visita a las páginas y la interacción por correo electrónico.

Esta evidencia es consistente con que los modelos predictivos superan a los sistemas tradicionales porque aprenden patrones complejos a partir del comportamiento histórico. Este punto fundamenta la selección de modelos del presente trabajo, aunque —como se documenta en el capítulo de resultados— la ventaja de los métodos de ensamble sobre la regresión logística no se reprodujo en el caso analizado.

6.7.1. Modelos analíticos aplicables al proceso comercial

Cuatro familias de aprendizaje supervisado resultan particularmente relevantes para un sistema de calificación de leads: regresión logística, árboles de decisión, *random forest* y *gradient boosting*.

Regresión logística. Constituye el punto de partida natural para la calificación de leads. Modela la probabilidad de conversión como una función sigmoide de una combinación lineal de las variables de entrada (Hosmer, Lemeshow, y Sturdivant, 2013):

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})}} \tag{6.1}$$

Equivalentemente, modela de forma lineal el logaritmo de la razón de momios:

$$\log\left(\frac{P(y = 1 \mid \mathbf{x})}{1 - P(y = 1 \mid \mathbf{x})}\right) = \beta_0 + \boldsymbol{\beta}^\top \mathbf{x} \tag{6.2}$$

La interpretación de los coeficientes permite conocer cómo cada variable influye en la probabilidad estimada de que ocurra el evento de interés. El signo del coeficiente indica la dirección de esta relación: un coeficiente positivo se asocia con una mayor probabilidad del evento, mientras que uno negativo se asocia con una menor probabilidad, manteniendo constantes las demás variables. Matemáticamente, al transformar el coeficiente mediante e^{β_i} se obtiene una medida de cuánto cambia la relación entre la probabilidad de que ocurra el evento y la probabilidad de que no ocurra ante un incremento unitario de x_i.

Esta facilidad de interpretación representa una ventaja en contextos donde las partes interesadas necesitan comprender cómo se toman las decisiones. Además, la regresión logística tiene un bajo costo computacional y genera estimaciones de probabilidad que pueden utilizarse para establecer umbrales operativos. Su calibración debe evaluarse empíricamente y, cuando sea necesario, ajustarse (Niculescu-Mizil y Caruana, 2005). Sin embargo, su desempeño puede ser limitado cuando existen relaciones no lineales complejas entre las variables, a menos que estas interacciones se incorporen explícitamente al modelo.

La regularización L2 es una técnica utilizada para evitar que el modelo dependa excesivamente de determinadas variables. Para ello, añade a la función de pérdida una penalización $\lambda\|\boldsymbol{\beta}\|_2^2$ que aumenta cuando los coeficientes del modelo adquieren valores elevados. Como resultado, el modelo favorece coeficientes de menor magnitud, lo que ayuda a reducir el sobreajuste y a mejorar su capacidad de generalización ante nuevos datos (Hastie y cols., 2009; James, Witten, Hastie, y Tibshirani, 2021). El parámetro λ controla la intensidad de esta penalización: cuanto mayor es su valor, mayor es la restricción aplicada a los coeficientes. En `scikit-learn`, este comportamiento se controla mediante el parámetro C, definido de forma inversa a la intensidad de regularización, de manera que valores menores de C implican una regularización más fuerte.

Árboles de decisión. Son útiles cuando las partes interesadas desean visualizar reglas condicionales explícitas. Resultan rápidos de entrenar e inherentemente interpretables, aunque tienden al sobreajuste, entendido como el ajuste excesivo a los datos de entrenamiento que impide generar predicciones precisas sobre datos distintos (IBM, s.f.).

Random forest. Es un conjunto de árboles de decisión construidos sobre muestras *bootstrap*, restringiendo el subconjunto de variables candidatas en cada división para descorrelacionar los árboles (Breiman, 2001). Tiende a obtener mayor exactitud y AUC que los árboles individuales, manteniéndose robusto frente al ruido. En aplicaciones de calificación de leads se han reportado exactitudes entre 82 % y 89 % con AUC superiores a 0.75 (Nygård y Mezei, 2020; Tan y cols., 2024). Sus limitaciones son la menor interpretabilidad y el mayor costo computacional.

Gradient boosting. Ajusta secuencialmente predictores débiles sobre los residuos del ensamble acumulado, corrigiendo los errores de los modelos previos (Hastie y cols., 2009). Alcanza AUC ligeramente superiores al *random forest* en conjuntos bien estructurados (Nygård y Mezei, 2020), aunque requiere un ajuste más cuidadoso y es más sensible a la calidad de los datos.

6.7.2. Codificación de variables categóricas

La codificación *one-hot* representa una variable categórica de m niveles mediante m variables binarias. Su limitación aparece con alta cardinalidad: categorías con muy pocas observaciones producen columnas casi constantes cuyo coeficiente estimado tiene varianza elevada, lo que introduce ruido y riesgo de sobreajuste. La práctica habitual consiste en agrupar en una categoría residual común aquellas categorías cuya frecuencia no alcanza un umbral mínimo.

6.8. El desbalance de clases

Un conjunto de datos está desbalanceado cuando la clase de interés representa una fracción reducida del total (Fernández y cols., 2018). El desbalance afecta al aprendizaje por dos vías: la función de pérdida queda dominada por la clase mayoritaria, y las métricas basadas en la exactitud dejan de discriminar entre modelos útiles e inútiles.

6.8.1. Estrategias de tratamiento

Las estrategias se agrupan en tres familias. Las de nivel de datos modifican la distribución de la muestra de entrenamiento mediante submuestreo de la clase mayoritaria o sobremuestreo de la minoritaria; la técnica SMOTE genera observaciones sintéticas interpolando entre cada instancia minoritaria y sus vecinos más cercanos (Chawla, Bowyer, Hall, y Kegelmeyer, 2002). Las de nivel de algoritmo incorporan pesos por clase en la función de pérdida, en la línea del aprendizaje sensible al costo (Elkan, 2001; Ling y Sheng, 2010). Las de nivel de decisión conservan el modelo y ajustan únicamente el umbral de clasificación.

Burez y Van den Poel (2009) evaluaron sistemáticamente estas alternativas en un problema de clasificación binaria con clase minoritaria muy escasa y encontraron que el remuestreo no siempre mejora el desempeño, particularmente cuando la métrica de interés es de ordenamiento y no de clasificación estricta.

Constituye un requisito metodológico que cualquier remuestreo se aplique exclusivamente a los pliegues de entrenamiento y nunca a los de validación: aplicarlo antes de particionar filtra información del conjunto de prueba y produce estimaciones optimistas.

6.9. Evaluación de modelos y definición de éxito

El desarrollo de los modelos es solo uno de los componentes del proceso analítico. La evaluación provee evidencia de que un modelo distingue confiablemente distintos resultados y de que puede apoyar la toma de decisiones dentro de un contexto de negocio específico. Dado que ninguna métrica captura por sí sola todos los aspectos del desempeño predictivo, resulta necesario emplear múltiples criterios (Provost y Fawcett, 2013; Abbott, 2015).

6.9.1. Matriz de confusión

La matriz de confusión es el marco fundamental para evaluar modelos de clasificación. Es una tabla de contingencia que compara las predicciones generadas con los valores reales observados (Han y cols., 2011). Está conformada por cuatro resultados posibles: verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN) (Provost y Fawcett, 2013).

En el contexto de la calificación de leads, estos resultados tienen implicaciones operativas directas. Un verdadero positivo representa un lead correctamente identificado como de alta probabilidad. Un falso positivo implica inversión de tiempo en un lead que no convierte. Un falso negativo representa una oportunidad perdida: un lead valioso que no recibe la atención necesaria para progresar.

6.9.2. Exactitud

La exactitud mide la proporción de casos clasificados correctamente respecto al total de observaciones evaluadas (Han y cols., 2011):

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN} \tag{6.3}$$

A pesar de su popularidad, presenta limitaciones severas en conjuntos desbalanceados. Cuando las conversiones representan una fracción pequeña del total, un modelo puede obtener exactitud elevada simplemente prediciendo la clase mayoritaria, aunque falle en identificar los positivos que interesan al negocio (Provost y Fawcett, 2013). En el caso analizado en este trabajo, con una tasa base de conversión del 1.18 % sobre el universo completo, un clasificador trivial supera el 98 % de exactitud sin aportar valor alguno.

6.9.3. Precisión

La precisión mide la proporción de predicciones positivas que son efectivamente correctas (Kuhn y Johnson, 2013):

$$\text{Precisión} = \frac{VP}{VP + FP} \tag{6.4}$$

Responde a la pregunta: de todos los leads identificados como probables de convertir, ¿cuántos realmente convirtieron? Resulta especialmente relevante cuando contactar un lead poco calificado representa un costo tangible en esfuerzo comercial o costo de oportunidad.

6.9.4. Sensibilidad

La sensibilidad o *recall* mide la proporción de positivos reales que el modelo identifica correctamente:

$$\text{Sensibilidad} = \frac{VP}{VP + FN} \tag{6.5}$$

Responde a la pregunta: de todos los leads que eventualmente convirtieron, ¿cuántos fueron identificados por el modelo? Es especialmente importante cuando el costo de no identificar un cliente potencial excede el costo de contactar a uno que no convierte. Maximizar la sensibilidad, sin embargo, incrementa el número de falsos positivos, lo que revela la necesidad de considerar ambas métricas de forma conjunta.

6.9.5. Curva ROC y ROC-AUC

La curva ROC es una herramienta gráfica que evalúa el desempeño de modelos de clasificación binaria a través de todos los umbrales posibles, mapeando la tasa de verdaderos positivos contra la tasa de falsos positivos (Fawcett, 2006).

Un umbral de clasificación es el límite de probabilidad utilizado para asignar cada observación a una clase. Los modelos predictivos generan probabilidades, y los leads se clasifican como positivos cuando su probabilidad estimada excede el umbral seleccionado. Modificar el umbral altera el número de predicciones positivas y, en consecuencia, las métricas de evaluación.

El área bajo la curva (ROC-AUC) resume esta información en un valor entre 0 y 1. Un valor de 0.5 representa discriminación equivalente al azar; 1.0 representa discriminación perfecta, mientras que valores inferiores a 0.5 indican un ordenamiento inverso respecto de la clase positiva (Hanley y McNeil, 1982; Fawcett, 2006). Su ventaja es la independencia respecto de un umbral específico. Diversos autores señalan, sin embargo, que puede resultar insuficiente para determinar el impacto operativo, dado que evalúa todos los umbrales posibles y no necesariamente refleja las condiciones bajo las cuales la organización opera (Hand, 2009; Drummond y Holte, 2006).

6.9.6. Curva precisión–sensibilidad y PR-AUC

Con clases fuertemente desbalanceadas, la curva ROC puede resultar excesivamente optimista, porque la tasa de falsos positivos se calcula sobre una clase mayoritaria muy numerosa y una cantidad grande de falsos positivos apenas la altera. La curva precisión–sensibilidad es preferible en este escenario, ya que ambas magnitudes se refieren exclusivamente a la clase minoritaria (Saito y Rehmsmeier, 2015). Davis y Goadrich (2006) establecieron la relación formal entre ambos espacios, demostrando que dominar en el espacio ROC implica dominar en el espacio precisión–sensibilidad, pero no a la inversa.

El área bajo esta curva (PR-AUC) tiene como referencia la tasa base de positivos y no el valor 0.5: sobre una tasa base de 0.033, un PR-AUC de 0.22 representa una mejora de casi siete veces respecto del azar.

6.9.7. Lift y curvas de ganancia

El *lift* es la razón entre la tasa de positivos en el subconjunto seleccionado por el modelo y la tasa base del universo (Piatetsky-Shapiro y Masand, 1999). Un *lift* de 4 en el primer decil indica que ese decil concentra cuatro veces más positivos de los que le corresponderían por azar.

La curva de ganancia acumulada representa, para cada porcentaje del universo ordenado por probabilidad descendente, la proporción de positivos capturada. Es la métrica que traduce de forma más directa el desempeño estadístico a capacidad operativa, y por ello resulta central en aplicaciones de mercadeo directo (Ling y Li, 1998) y en la evaluación de modelos orientada al ordenamiento (Provost y Domingos, 2003).

6.10. Métricas secundarias de evaluación

Debido al desbalance de clases presente en el conjunto de datos, la evaluación del modelo no se limitó a una medida única de desempeño. En particular, la exactitud global puede ofrecer una apreciación excesivamente favorable cuando la clase mayoritaria concentra gran parte de las observaciones, ya que un clasificador puede alcanzar un porcentaje alto de aciertos aun sin identificar adecuadamente la clase minoritaria. Por ello, las métricas secundarias se calcularon sobre predicciones fuera de muestra, es decir, sobre observaciones no empleadas para ajustar el modelo. Este procedimiento permite estimar el desempeño de generalización y reducir el sesgo optimista derivado de evaluar el modelo en los mismos datos utilizados durante el entrenamiento.

Se emplearon el área bajo la curva ROC, el Brier score, el coeficiente de correlación de Matthews y el estadístico κ de Cohen. En conjunto, estas métricas evalúan dimensiones complementarias del desempeño: la capacidad de discriminación, la calidad de las probabilidades estimadas, la asociación entre las clases observadas y predichas, y el acuerdo entre dichas clasificaciones una vez descontado el componente atribuible al azar.

6.10.1. Área bajo la curva ROC

El área bajo la curva ROC (*Receiver Operating Characteristic Area Under the Curve*, ROC-AUC) se utilizó para evaluar la capacidad discriminativa del modelo. La curva ROC representa, para distintos umbrales de clasificación, la relación entre la sensibilidad o tasa de verdaderos positivos y la tasa de falsos positivos. Por consiguiente, el ROC-AUC resume la capacidad del modelo para diferenciar entre las observaciones pertenecientes a la clase positiva y aquellas pertenecientes a la clase negativa.

Hanley y McNeil (1982) establecieron una interpretación probabilística ampliamente aceptada del área bajo la curva ROC: esta representa "*the probability that a randomly chosen diseased subject is correctly rated or ranked with greater suspicion than a randomly chosen non-diseased subject*" (p. 29) [la probabilidad de que un caso positivo seleccionado aleatoriamente reciba una puntuación o clasificación superior a la de un caso negativo seleccionado aleatoriamente; traducción propia]. En el contexto de esta investigación, un ROC-AUC elevado indica que el modelo tiende a asignar mayores puntuaciones o probabilidades a los casos de la clase positiva que a los de la clase negativa.

El ROC-AUC toma valores entre 0 y 1. Un valor de 1 representa discriminación perfecta, mientras que un valor de 0.5 indica una capacidad discriminativa equivalente al azar. No obstante, esta métrica no permite determinar si las probabilidades estimadas son numéricamente precisas. Un modelo puede discriminar adecuadamente entre ambas clases y, al mismo tiempo, sobreestimar o subestimar de forma sistemática

la probabilidad real del evento. Por ello, el ROC-AUC se complementó con el Brier score, el cual evalúa directamente el desempeño de las predicciones probabilísticas.

6.10.2. Brier score

El Brier score se empleó como una medida de desempeño probabilístico global. Esta métrica calcula el error cuadrático medio entre la probabilidad predicha de que ocurra un evento y el resultado observado. Para un desenlace binario, se expresa como:

$$\text{Brier score} = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)^2, \tag{6.6}$$

donde $\hat{p}_i$ corresponde a la probabilidad predicha de pertenecer a la clase positiva para la observación i, y y_i representa el resultado observado, con valor 1 cuando el evento ocurre y 0 cuando no ocurre.

Brier (1950) propuso esta aproximación para la "*verification of forecasts expressed in terms of probability*" (p. 1) [verificación de pronósticos expresados en términos de probabilidad; traducción propia]. En términos prácticos, el Brier score penaliza la diferencia entre la probabilidad asignada por el modelo y el resultado real; además, penaliza con mayor severidad las predicciones erróneas realizadas con alta confianza. Por ejemplo, si el modelo asigna una probabilidad de 0.90 a un evento que finalmente no ocurre, el error individual es $(0.90 - 0)^2 = 0.81$. En cambio, si asigna una probabilidad de 0.55 al mismo evento no observado, el error es $(0.55 - 0)^2 = 0.3025$.

El Brier score adopta valores menores cuando las probabilidades predichas se aproximan más a los resultados observados; el valor óptimo es 0. En consecuencia, esta medida complementa el ROC-AUC: mientras este último evalúa la capacidad del modelo para ordenar correctamente los casos positivos y negativos, el Brier score evalúa la exactitud global de las probabilidades generadas. Debe precisarse que el Brier score no constituye, por sí solo, una medida exclusiva de calibración; más bien, refleja el desempeño probabilístico global e incorpora aspectos vinculados tanto con la calibración como con la discriminación (Riley y cols., 2024).

6.10.3. Coeficiente de correlación de Matthews

El coeficiente de correlación de Matthews (*Matthews Correlation Coefficient*, MCC) se utilizó como una medida complementaria para evaluar la concordancia entre las etiquetas observadas y las etiquetas predichas por el modelo (Matthews, 1975). El MCC se calcula a partir de los cuatro componentes de la matriz de confusión: verdaderos positivos (TP), verdaderos negativos (TN), falsos positivos (FP) y falsos negativos (FN):

$$\text{MCC} = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}. \tag{6.7}$$

El coeficiente oscila entre -1 y 1. Un valor de 1 representa una clasificación perfecta; un valor de 0 indica que no existe asociación predictiva superior a la esperada por azar; y un valor de -1 refleja una clasificación completamente inversa a las clases verdaderas.

Chicco y Jurman (2020) sostienen que el MCC "*produces a high score only if the prediction obtained good results in all of the four confusion matrix categories*" (p. 2) [produce una puntuación alta únicamente si la predicción obtiene buenos resultados en las cuatro categorías de la matriz de confusión; traducción propia]. Esta característica es especialmente relevante ante el desbalance de clases, debido a que impide que el desempeño del modelo sea valorado positivamente solo por clasificar correctamente los casos de la categoría predominante.

A diferencia del ROC-AUC y del Brier score, el MCC se calcula sobre etiquetas de clase y no sobre probabilidades continuas. Por tanto, su estimación requiere definir un umbral para transformar las probabilidades predichas en clasificaciones finales. Dicho umbral debe establecerse según el objetivo del modelo, la prevalencia de la clase positiva y las consecuencias asociadas con falsos positivos y falsos negativos.

6.10.4. Estadístico κ de Cohen

El estadístico κ de Cohen se empleó para cuantificar el acuerdo entre las clases observadas y las etiquetas predichas, descontando la proporción de acuerdo que podría ocurrir por azar. Se calcula mediante la siguiente expresión:

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \tag{6.8}$$

donde p_o representa la proporción de acuerdo observada entre las clasificaciones reales y predichas, mientras que p_e corresponde a la proporción de acuerdo esperada por azar a partir de las distribuciones marginales de las categorías.

Cohen (1960) definió este estadístico como una medida de "*agreement corrected for chance*" (p. 37) [acuerdo corregido por azar; traducción propia]. Aunque inicialmente se propuso para evaluar la concordancia entre evaluadores que asignan categorías nominales, puede aplicarse a la comparación entre las etiquetas reales y las etiquetas generadas por un clasificador.

El valor de κ puede variar entre -1 y 1. Un valor de 1 representa concordancia perfecta; un valor de 0 indica un acuerdo equivalente al esperado por azar; y los valores negativos indican un acuerdo inferior al que se esperaría aleatoriamente. Su principal utilidad en el presente estudio radica en que complementa la exactitud global, dado que una proporción elevada de aciertos puede ser parcialmente atribuible a la distribución predominante de una de las clases.

No obstante, el estadístico κ puede verse afectado por la prevalencia de las categorías y por la distribución marginal de las predicciones. Por ello, su interpretación se realizó de forma conjunta con la matriz de confusión, el coeficiente de Matthews, el ROC-AUC y el Brier score, evitando atribuir el desempeño del modelo a una única métrica.

6.11. Validación de modelos

La validación cruzada estratificada de k pliegues divide el conjunto en k subconjuntos preservando la proporción de clases, entrena k modelos y evalúa cada uno sobre el pliegue que no observó (James y cols., 2021). La estratificación es indispensable cuando la clase minoritaria es escasa, pues una partición aleatoria simple puede producir pliegues sin casos positivos.

Las predicciones *out-of-fold* consisten en asignar a cada observación la predicción del modelo que no la incluyó en su entrenamiento. Esto permite construir un vector de predicciones honestas para la totalidad del conjunto, sobre el cual calcular métricas globales sin reservar una porción de los datos.

6.11.1. Fuga de información

La fuga de información ocurre cuando el conjunto de predictores incorpora, directa o indirectamente, información que no estaría disponible en el momento en que la predicción debe emitirse. Es especialmente frecuente en datos provenientes de sistemas transaccionales, donde ciertos campos se completan únicamente después de que el desenlace ha ocurrido. Su síntoma característico es un desempeño de validación anormalmente alto que se desploma al desplegar el modelo.

6.11.2. Interpretación del modelo

La importancia por permutación permite evaluar cuánto depende el desempeño del modelo de cada variable. Para calcularla, los valores de una variable se desordenan aleatoriamente, mientras las demás permanecen sin cambios, y se observa cuánto disminuye el desempeño del modelo. Una caída mayor indica que la variable tenía mayor importancia para realizar las predicciones. Este procedimiento no requiere volver a entrenar el modelo y puede aplicarse a distintos tipos de algoritmos (Breiman, 2001).

Los valores SHAP complementan este análisis al explicar cómo contribuye cada variable a las predicciones realizadas por el modelo. Para una observación específica, permiten identificar qué variables aumentaron o disminuyeron la predicción y en qué medida. El método se fundamenta en los valores de Shapley, provenientes

de la teoría de juegos cooperativos, para distribuir la predicción entre las distintas variables de acuerdo con su contribución (Lundberg y Lee, 2017).

6.12. Segmentación mediante análisis de conglomerados

La segmentación de clientes mediante algoritmos de agrupamiento es una técnica establecida en el análisis de mercados (Kaufman y Rousseeuw, 1990).

6.12.1. El algoritmo K-Means

K-Means (MacQueen, 1967; Lloyd, 1982) particiona n observaciones en k grupos minimizando la suma de cuadrados intra-cluster:

$$\min_{S_1,\ldots,S_k} \sum_{j=1}^{k} \sum_{\mathbf{x}_i \in S_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2 \tag{6.9}$$

donde $\boldsymbol{\mu}_j$ es el centroide del grupo S_j. El algoritmo alterna entre asignar cada observación a su centroide más cercano y recalcular los centroides hasta la convergencia. Al tratarse de una optimización local, el resultado depende de la inicialización, por lo que la práctica estándar consiste en ejecutar múltiples inicializaciones y retener la de menor inercia.

6.12.2. Escalamiento y ponderación

K-Means opera sobre distancias euclidianas, por lo que es sensible a la escala de las variables. Cuando conviven variables continuas con categóricas codificadas mediante *one-hot* surge un problema adicional: un bloque categórico de m niveles aporta m dimensiones a la distancia, de modo que las variables con más categorías pesan artificialmente más. Una corrección habitual consiste en dividir cada bloque entre $\sqrt{m}$, igualando su contribución esperada a la distancia total. La winsorización —recorte de valores extremos a un múltiplo del rango intercuartílico— limita la influencia de observaciones atípicas sobre la posición de los centroides.

6.12.3. Evaluación de la calidad del agrupamiento

Al no existir una etiqueta de referencia, la calidad se evalúa mediante índices internos:

Coeficiente de silueta. Compara, para cada observación, su distancia media a su propio grupo con su distancia media al grupo vecino más cercano (Rousseeuw, 1987). Toma valores en $[-1, 1]$.

Índice de Davies–Bouldin. Razón media entre dispersión intra-cluster y separación entre centroides (Davies y Bouldin, 1979). Valores menores son mejores.

Índice de Calinski–Harabasz. Razón entre dispersión inter-cluster e intra-cluster (Caliński y Harabasz, 1974). Valores mayores son mejores.

El índice de Rand ajustado mide la coincidencia entre dos particiones corrigiendo por el acuerdo esperado al azar, y resulta útil para verificar la estabilidad de una solución al reentrenarla sobre un universo distinto. Ninguno de estos índices sustituye el criterio de interpretabilidad: una partición con índices excelentes pero grupos sin lectura sustantiva carece de valor para la toma de decisiones (Kaufman y Rousseeuw, 1990).

6.12.4. Validación externa mediante una variable no utilizada

Cuando se dispone de una variable de resultado que no participó en la formación de los grupos, contrastar su distribución entre clusters constituye una validación externa: si los grupos formados solo con atributos de perfil muestran resultados significativamente distintos, la partición captura estructura con relevancia sustantiva y no meramente geométrica.

6.13. Pruebas estadísticas empleadas

ANOVA de una vía y Tukey HSD. Contrastan si las medias de una variable continua difieren entre grupos y, en caso afirmativo, qué pares específicos difieren controlando el error por comparaciones múltiples (Tukey, 1949).

Prueba χ^2 y V de Cramér. Evalúan la asociación entre dos variables categóricas. La V de Cramér normaliza el estadístico χ^2 al intervalo $[0, 1]$, proporcionando un tamaño de efecto comparable entre variables con distinto número de categorías (Cramér, 1946).

Intervalo de confianza de Wilson. Intervalo para una proporción binomial con mejor cobertura que la aproximación normal cuando la proporción es cercana a cero (Wilson, 1927).

Prueba de dos proporciones. Contrasta si la proporción observada en un subgrupo difiere significativamente de la del resto de la población.

6.14. Simulación de Monte Carlo

Los métodos de Monte Carlo estiman propiedades de una distribución mediante muestreo aleatorio repetido (Raychaudhuri, 2008; Rubinstein y Kroese, 2016). Su utilidad en este contexto es construir una distribución de referencia empírica: al extraer repetidamente subconjuntos aleatorios del universo de leads y contar las conversiones capturadas, se obtiene la distribución completa del resultado que produciría la ausencia de priorización.

Cuando el muestreo es sin reemplazo desde una población finita con N elementos de los cuales K son positivos, el número de positivos en una extracción de tamaño n sigue exactamente una distribución hipergeométrica:

$$P(X = x) = \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}} \tag{6.10}$$

La disponibilidad de la forma analítica permite verificar que las conclusiones obtenidas por simulación no dependen del error de muestreo asociado a un número finito de iteraciones.

6.15. Gestión por procesos y notación BPMN

La gestión de procesos de negocio concibe la organización como un conjunto de procesos interrelacionados susceptibles de ser modelados, medidos y mejorados de forma sistemática (Dumas, La Rosa, Mendling, y Reijers, 2018). Su ciclo de vida comprende la identificación del proceso, su descubrimiento y modelado, el análisis de sus ineficiencias, el rediseño, la implementación y el monitoreo.

BPMN es el estándar de notación gráfica para representar procesos de negocio (Object Management Group, 2011). Define un vocabulario de eventos, actividades, compuertas de decisión, flujos y carriles de responsabilidad que permite representar de forma inequívoca quién ejecuta cada actividad y bajo qué condición. Su valor en un proyecto analítico es doble: documenta el proceso comercial existente con precisión suficiente para identificar en qué punto del flujo debe insertarse la intervención analítica, y proporciona un lenguaje común entre el equipo técnico y las áreas de negocio.

6.16. Metodología CRISP-DM

CRISP-DM describe las fases típicas de un proyecto de minería de datos, las tareas asociadas a cada una y las relaciones entre ellas, ofreciendo una visión integral del ciclo de vida analítico (Chapman y cols., 2000; Hotz, 2018). La metodología consiste en seis etapas:

1. **Entendimiento del negocio**, donde se definen los objetivos y el criterio de éxito.
2. **Entendimiento de los datos**, incluyendo recolección, exploración y evaluación de su calidad.

3. **Preparación de los datos**, incluyendo selección, limpieza, integración y transformación.
4. **Modelado**, con selección de técnicas, diseño de los conjuntos de entrenamiento y prueba, construcción y ajuste de modelos.
5. **Evaluación**, donde se verifica si el modelo cumple con los requerimientos del negocio.
6. **Implementación**, que incluye la planificación para producción y el monitoreo del modelo.

Su naturaleza cíclica permite regresar a etapas anteriores cuando se detectan problemas o nuevas oportunidades. Esta propiedad resultó determinante en el presente trabajo: los hallazgos de la fase de preparación —en particular la estructura de la ausencia de datos— obligaron a redefinir el universo de modelado después de haber avanzado en la fase de evaluación.

Capítulo 7

Metodología

La metodología de este trabajo profesional se diseñó bajo el enfoque de proceso estándar de minería de datos CRISP-DM. Esta estructura permite integrar sistemáticamente la gestión de procesos comerciales con el desarrollo de modelos predictivos y de segmentación, asegurando una secuencia lógica desde la comprensión del negocio hasta la operacionalización de las herramientas analíticas.

7.1. Entendimiento del negocio

El estudio se llevó a cabo en el departamento comercial de una empresa desarrolladora de vivienda que opera proyectos residenciales en la Ciudad de Guatemala. La unidad de análisis se definió como el cliente potencial o *lead*, identificado mediante el identificador de trato comercial en el sistema de gestión de relaciones con clientes (CRM).

Como variable de respuesta para los modelos predictivos de conversión se estableció la variable binaria `target_won`, que asigna el valor de 1 si el cliente concreta la reserva de una vivienda, y 0 en caso contrario. La reserva se adoptó como punto de corte del proceso de conversión comercial porque representa el primer compromiso económico verificable del prospecto, excluyendo etapas posteriores que dependen de factores financieros externos no registrados en los sistemas comerciales de la empresa.

Por motivos de confidencialidad, los proyectos residenciales incluidos en el estudio se presentan mediante pseudónimos. Estos se utilizan de manera consistente a lo largo del documento y no guardan relación con el nombre comercial de los proyectos originales.

7.1.1. Mapeo del proceso comercial

Para estructurar la comprensión del negocio, se diseñó un procedimiento de levantamiento de información basado en entrevistas semiestructuradas con los equipos de mercadeo, asesores comerciales y gestores de inteligencia de negocios.

La información recopilada se sintetizó en un modelo formal utilizando la notación estándar de modelado de procesos de negocio (BPMN). Este modelado se diseñó con el propósito procedimental de:

1. Identificar las actividades secuenciales, las compuertas de decisión y los carriles de responsabilidad que componen el flujo desde la recepción del lead hasta la conversión.

2. Determinar el punto exacto del flujo operativo donde debe insertarse la predicción para optimizar la toma de decisiones comercial.

3. Evaluar la disponibilidad temporal de la información, distinguiendo las variables que se registran de manera natural en las etapas tempranas de aquellas que se generan en fases tardías del embudo de ventas.

7.2. Entendimiento de los datos

El estudio contempló el análisis de las bases de datos históricas extraídas del CRM comercial para los proyectos residenciales de la empresa. Procedimentalmente, se diseñó una fase de inventario y diagnóstico para evaluar la estructura de los archivos recibidos, la correspondencia entre los campos de las distintas fases de extracción y la calidad general de la información.

Para caracterizar el conjunto de datos de partida, se programó un análisis exploratorio de datos (EDA) orientado a medir de forma cuantitativa:

- La tasa de completitud de cada variable, identificando el porcentaje de valores faltantes.
- La cardinalidad y distribución de frecuencias de las variables categóricas.
- La distribución y el balance de clases de la variable objetivo de conversión.

Los resultados de este diagnóstico exploratorio se reportan de forma detallada en el Capítulo 8.

7.3. Preparación de los datos

A partir de las fuentes crudas del CRM, se construyó un flujo de procesamiento secuencial en Python para transformar la información en conjuntos de datos validados para el modelado. Este flujo se estructuró en las siguientes etapas procedimentales: unificación de nomenclaturas de archivos, consolidación de registros eliminando duplicados mediante el identificador de trato comercial, depuración de registros de prueba internos del sistema, y estandarización del formato de las variables de texto.

7.3.1. Tratamiento diferenciado de la ausencia de datos

En lugar de recurrir a la imputación masiva tradicional de valores faltantes (como la sustitución sistemática por la media o la moda), se diseñó un tratamiento adaptado a la naturaleza de cada variable:

Para las variables categóricas (de texto), los valores nulos se transformaron en una categoría explícita denominada `_missing_` dentro de la misma columna. Esto permite al modelo tratar la omisión como una opción de comportamiento más dentro del proceso comercial.

Por otro lado, para las variables continuas o numéricas, no es posible registrar texto. En estos casos, se imputó el valor faltante con un valor de respaldo (la mediana) y se programó la creación de una columna nueva e independiente de carácter binario, el indicador de ausencia. Este indicador toma el valor de 1 si el dato original estaba ausente y 0 si estaba completo, permitiendo que el modelo identifique cuándo el valor numérico corresponde a un registro real o a una imputación técnica. Este tratamiento aplica a las variables numéricas que se mantienen como opcionales dentro de un universo de modelado dado; las variables definidas como obligatorias mediante el criterio de completitud descrito a continuación quedan completas por construcción, ya que los registros que no las reportan se excluyen directamente del universo, por lo que no requieren imputación ni indicador de ausencia.

7.3.2. Definición de universos mediante el embudo de completitud

La exigencia de datos completos para múltiples variables reduce el tamaño del conjunto de datos utilizable. Para medir este efecto de manera procedimental, se diseñó un embudo de completitud acumulado que registra de forma secuencial la pérdida marginal de observaciones y de conversiones reales a medida que se agrega cada variable de perfil.

El embudo se utilizó para cuantificar el costo de completitud asociado a cada variable y detectar hasta qué punto un criterio de casos completos reducía las observaciones y conversiones disponibles. La definición definitiva de las variables obligatorias y opcionales se realizó de manera iterativa con la etapa de modelado: además de su efecto sobre el tamaño del universo, se consideró la evidencia obtenida mediante análisis de ablación y procedimientos de selección de variables. De esta forma, la ausencia se flexibilizó para aquellas variables cuya exclusión como requisito permitía recuperar observaciones sin prescindir de señal predictiva relevante, mientras que las variables que aportaban información sustantiva al modelo se mantuvieron como requisitos de completitud. El conjunto resultante se denominó Universo H.

En la definición final del Universo H se exigió disponibilidad en `fuente_pt2`, `canal_de_anuencia`, `canal_de_contacto`, `ingreso_familiar` y `edad`. Las demás variables de perfil se mantuvieron como opcionales, de modo que su ausencia no implicara la exclusión completa del registro y se tratara conforme al procedimiento descrito en la sección anterior.

Antes de converger en este criterio, se exploraron definiciones alternativas del universo de modelado, contrastando conjuntos de variables obligatorias definidos manualmente,agregando variables de forma progresiva según su relevancia de negocio (canal, canal más edad, canal más edad y lugar de trabajo), con un conjunto obtenido mediante selección automática. Este último se determinó mediante un procedimiento de eliminación hacia atrás (*backward elimination*): partiendo del conjunto completo de variables candidatas, se removió en cada iteración la variable cuya ausencia producía la menor pérdida de desempeño en PR-AUC, deteniendo el proceso cuando ninguna eliminación adicional era posible sin deteriorar el modelo por encima de un umbral de tolerancia predefinido.

El modelo de segmentación no comparte este universo. Al requerir las cinco variables de perfilamiento que definen los clusters —`edad`, `sexo`, `estado_civil`, `razon_de_compra` y `tipo_unidad`—, conforma un conjunto propio, el Universo S, sobre el mismo extracto de leads calificados. Ambos universos se detallan en el Capítulo 8.

7.3.3. Construcción de variables derivadas

Como parte de la preparación para el modelado, se construyeron variables derivadas a partir de los campos originales del CRM con el propósito de reducir la fragmentación de variables categóricas y representar relaciones que no estaban disponibles directamente en la base. En particular, las categorías de `canal_de_anuencia` se agruparon en siete familias: pauta digital, portal, contacto directo, referido, presencial, exterior y otros. A partir de esta clasificación se generó además el indicador binario `es_referido`.

La variable `campania` también se descompuso en características que permitieran representar de forma estructurada la información contenida en los nombres de las campañas, en lugar de utilizar cada denominación como una categoría independiente. De esta transformación se obtuvieron las variables derivadas de campaña utilizadas posteriormente en el modelado, entre ellas `campania_plataforma`, `campania_tipo` y `campania_audiencia`. Las reglas de clasificación aplicadas a cada denominación se presentan en el Anexo D.

Para las variables numéricas y de perfil se construyeron representaciones adicionales. El rango de `ingreso_familiar` se transformó a su punto medio como `ingreso_mid`, y se generaron indicadores derivados de edad, ingreso y razón de compra. Asimismo, se incorporaron cuatro términos de interacción entre edad, ingreso, motivación de inversión y condición de referido para permitir que los modelos evaluaran relaciones conjuntas entre estas características. La utilidad de estas variables se determinó posteriormente durante la comparación de especificaciones y el análisis de importancia de predictores.

7.4. Estrategia de modelado e iteración experimental

Para identificar los modelos definitivos, se diseñó un marco de experimentación estructurado en rondas sistemáticas de entrenamiento y optimización, el cual abarca tanto algoritmos de aprendizaje supervisado como no supervisado.

7.4.1. Segmentación de clientes (K-Means)

El componente de segmentación se diseñó para identificar perfiles típicos de leads calificados utilizando el algoritmo K-Means. Para garantizar una validación honesta y evitar análisis circulares, la variable de éxito `target_won` se excluyó estrictamente de la etapa de entrenamiento, reservándose únicamente como un validador externo posterior.

El diseño experimental de la segmentación contempló la evaluación de una **matriz combinatoria de parámetros**, variando de forma sistemática:

- Los universos de variables de entrada (perfil demográfico frente a variables de adquisición).
- Los esquemas de codificación categórica y de normalización geométrica para evitar que los bloques de variables con mayor número de categorías dominen la distancia euclidiana.

- La ponderación relativa de la edad continua frente a las características categóricas del lead.

El rendimiento interno de cada configuración se evaluó para soluciones de k grupos utilizando el coeficiente de silueta y los índices de Davies–Bouldin y Calinski–Harabasz. Los experimentos de búsqueda y la caracterización geométrica de los segmentos ganadores se reportan en el Capítulo 8.

7.4.2. Modelo predictivo de conversión

El desarrollo del modelo predictivo se organizó en rondas sucesivas de experimentación, en las que se variaron los conjuntos de variables, los algoritmos de clasificación, las estrategias de tratamiento del desbalance, los universos de modelado y, posteriormente, los hiperparámetros y procedimientos de selección de variables. La exploración más amplia comparó seis conjuntos de predictores con nueve algoritmos; las estrategias adicionales de balanceo se evaluaron sobre un subconjunto de las combinaciones con mayor interés, en lugar de aplicar todas las alternativas a cada configuración posible.

Para asegurar la robustez del ordenamiento y evitar el sobreajuste, cada configuración se evaluó mediante validación cruzada estratificada de cinco pliegues con estimación de predicciones fuera de la partición de entrenamiento o *out-of-fold*. El ajuste del modelo seleccionado se optimizó mediante búsqueda aleatorizada de hiperparámetros.

La selección del conjunto de variables predictoras se guió por el análisis de ablación por familias de variables y por los procedimientos de eliminación hacia atrás sobre la métrica PR-AUC descritos antes, con el criterio explícito de descartar las variables que inducen al algoritmo a memorizar la tasa de éxito histórica o los atributos físicos de proyectos específicos —lo que provocaría un colapso del rendimiento al evaluar un desarrollo nuevo— y de conservar las características de comportamiento del prospecto.

Como comprobación complementaria de estabilidad geográfica se realizó una validación cruzada por exclusión de proyectos (*Leave-One-Project-Out Cross-Validation* o LOGO-CV), que entrena el modelo con $N - 1$ proyectos y lo evalúa sobre el proyecto restante, repitiendo el ciclo hasta que cada desarrollo actúa como conjunto de prueba.

7.4.3. Decisiones metodológicas críticas

Prevención de fuga de información: Se aplicó un criterio estricto para excluir de la lista de variables predictoras todo campo del CRM que registre transacciones, estados o interacciones posteriores al evento de reserva (tales como la asignación física de parqueos, bodegas, apartamentos o encuestas de satisfacción postventa).

Diseño orientado a la portabilidad del modelo: Para favorecer la aplicabilidad de los modelos en desarrollos inmobiliarios futuros de la empresa, se excluyó deliberadamente la identidad del proyecto residencial de la lista de características predictoras. De incluirse, el modelo tendería a memorizar el éxito de los proyectos existentes en lugar de aprovechar los atributos de comportamiento del lead.

7.5. Estrategia de evaluación técnica y operacional

Para validar la utilidad del sistema de priorización, el rendimiento de las configuraciones predictivas se analizó bajo dos planos de decisión complementarios: el analítico (técnico) y el operativo (comercial).

7.5.1. Evaluación técnica analítica

Este plano se enfoca en medir la capacidad intrínseca del modelo para ordenar y clasificar la cartera de clientes utilizando predicciones fuera de muestra (*out-of-fold*). Debido al desbalance severo de clases registrado en el negocio, se seleccionaron métricas robustas que evitan estimaciones sesgadas:

- **Métrica principal (PR-AUC):** El área bajo la curva precisión–*recall* se adoptó como criterio principal de evaluación. Esta métrica resume la relación entre la proporción de conversiones identificadas y la precisión obtenida al priorizarlas, por lo que resulta especialmente informativa cuando la clase de interés representa una proporción reducida del conjunto de datos.

- **Calibración probabilística (Brier score):** Se utilizó para medir la confiabilidad de las probabilidades estimadas. El Brier score evalúa la desviación cuadrática media entre la probabilidad predicha por la regresión logística y el desenlace real de conversión.
- **Métricas de acuerdo complementarias:** Se reportan el área bajo la curva ROC (ROC-AUC), el coeficiente de correlación de Matthews (MCC) y el estadístico κ de Cohen. Estos dos últimos coeficientes evalúan la matriz de confusión completa actuando como correctores por azar, lo cual penaliza severamente a los modelos triviales que se ven favorecidos por el desbalance extremo de los datos.

7.5.2. Evaluación operativa mediante simulación de Monte Carlo

La evaluación operativa traduce el rendimiento estadístico del modelo en valor práctico para el negocio. Simula escenarios reales donde la fuerza de ventas posee restricciones de capacidad de contacto y evalúa cuántas ventas se capturan al priorizar con el modelo frente a atender la cartera en orden arbitrario (enfoque al azar). Para garantizar la robustez metodológica, esta comparación se contrastó mediante tres vías analíticas independientes:

1. **Simulación a escala operativa (1,000 iteraciones):** Diseñada para modelar el rendimiento promedio esperado de un equipo comercial que selecciona leads al azar bajo diferentes escenarios de capacidad comercial (cortes del Top 5 %, 10 %, 20 % y 30 %). Esta simulación empírica permite definir los intervalos de confianza del 95 % del azar para identificar mejoras comercialmente significativas.
2. **Simulación de alta resolución (200,000 iteraciones):** Estructurada específicamente para auditar la estabilidad estadística del proceso, asegurando que las estimaciones en los percentiles extremos (las colas de la distribución aleatoria) permanezcan estables y libres del ruido de muestreo. Aplicada a los ocho niveles de capacidad analizados, esta vía acumula cerca de 1,6 millones de extracciones aleatorias.
3. **Distribución analítica exacta:** Modelada formalmente bajo la teoría de muestreo sobre poblaciones finitas para calcular de forma directa la probabilidad teórica del azar, eliminando cualquier error de muestreo o sesgo de simulación numérica. Dado que el proceso de prospección aleatoria equivale a extraer de forma consecutiva y sin reemplazo registros dentro de una cartera cerrada, la distribución del conteo de conversiones obtenidas se rige con absoluta precisión matemática por una distribución hipergeométrica $H(N, K, n)$, cuya función de probabilidad para registrar exactamente x éxitos se define como:

$$P(X = x) = \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}} \tag{7.1}$$

   donde los parámetros poblacionales fijos corresponden a las dimensiones del universo de modelado definido (N representa el total de registros de clientes calificados que componen dicho universo, y K denota la cantidad de éxitos o reservas físicas reales registradas históricamente en él), mientras que n representa la capacidad de contacto o tamaño de muestra evaluada bajo el escenario operativo correspondiente.

   Metodológicamente, para evaluar la significancia de la señal predictiva del modelo, este estándar calcula la función de supervivencia o probabilidad acumulada de la cola superior. Esta métrica determina la probabilidad analítica exacta de que la selección aleatoria iguale o supere el número de éxitos m obtenidos por la priorización inteligente del modelo final:

$$P(X \geq m) = \sum_{x=m}^{\min(n,K)} \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}} \tag{7.2}$$

   Al resolver analíticamente esta sumatoria, el procedimiento calcula el valor de probabilidad (p-value) y la distancia en desviaciones estándar (z-score) del desempeño del modelo respecto a la media teórica esperada por el azar.

La comparación sistemática de estas tres vías metodológicas garantiza que la ventaja del modelo sobre el azar no sea producto del ruido de simulación, sentando las bases estadísticas para los resultados que se reportan detalladamente en el Capítulo 8.

7.6. Implementación y transferencia de conocimiento

La fase final de la metodología se diseñó como un proceso sistemático de transferencia de conocimiento, orientado a garantizar que la organización pueda adoptar, operar e integrar las soluciones analíticas de forma sostenible dentro de sus sistemas comerciales y flujos de trabajo actuales. El despliegue de los modelos predictivos y de segmentación se estructuró bajo dos frentes complementarios: el cumplimiento de tres restricciones técnicas fundamentales en el diseño del software y el desarrollo de un marco documental compuesto por cuatro guías técnicas y operativas.

7.6.1. Restricciones estructurales del diseño técnico

Para asegurar la estabilidad de la infraestructura informática existente y minimizar la resistencia al cambio por parte de los administradores de sistemas, el desarrollo del componente de cálculo (`scoring_leads`) se rigió por tres criterios de ingeniería:

1. **No intrusión:** El componente opera bajo un esquema pasivo de "solo lectura"sobre el conjunto de datos de entrada. Lee la tabla que el entorno de visualización comercial (Power BI) le entrega en memoria y devuelve la misma estructura con idéntico orden, anexando únicamente las columnas de prioridad y perfilamiento. Esto evita la necesidad de realizar escrituras directas, reestructuraciones de bases de datos o modificaciones intrusivas en el sistema de gestión de relaciones con clientes (CRM) de la empresa.

2. **Consistencia de la calificación:** Los modelos se cargan ya entrenados y serializados, por lo que un lead con los mismos atributos recibe la misma puntuación predictiva y, cuando dispone de la información requerida, la misma asignación de grupo. El percentil se calcula posteriormente a partir de la posición relativa de esa puntuación dentro de la cartera procesada; por esta razón, puede variar cuando cambia la composición del conjunto de leads, aun cuando la puntuación individual permanezca constante.

3. **Legibilidad operativa para el usuario final:** Para facilitar la interpretación del ordenamiento, la puntuación predictiva se expresa adicionalmente como un percentil relativo dentro de la cartera procesada. Esta representación permite identificar con mayor claridad la posición de cada lead respecto del resto de los prospectos. El componente devuelve además la asignación de grupo y utiliza el valor de control -1 cuando no existe información suficiente para realizar la segmentación.

7.6.2. Marco documental para la transferencia operativa

Con el propósito de mitigar la brecha de adopción técnica entre los desarrolladores y las áreas usuarias, se diseñó una biblioteca documental compuesta por cuatro guías y manuales de operación procedimentales, detallados en el Anexo J:

1. **Guía de implementación técnica del tablero (Paso 1)** (Anexo J)**:** Escrita específicamente para los analistas de inteligencia de negocios o administradores de base de datos encargados de conectar el informe al CRM de la empresa y programar su actualización automática. Este documento detalla la migración de la consulta de datos desde el entorno de pruebas local hacia el entorno productivo, describe la validación de compatibilidad de los nombres canónicos de variables del lead, y define las tres alternativas de configuración de la puerta de enlace en la nube para el refresco automatizado.

2. **Guía técnica de scoring y configuración del entorno (Paso 2)** (Anexo J)**:** Dirigida al administrador de sistemas responsable de la infraestructura de soporte de TI. Este manual establece el procedimiento paso a paso para la instalación del entorno de ejecución de Python, la configuración de dependencias de software con versiones estrictas para evitar incompatibilidades silenciosas (particularmente con la biblioteca de aprendizaje automático utilizada para la serialización de modelos) y el procedimiento técnico para integrar el script de orquestación en la interfaz de consultas de Power Query.

3. **Manual de uso para el equipo comercial (Guía del dashboard)** (Anexo J)**:** Diseñado como un recurso de formación operativa para asesores comerciales, analistas de mercadeo y gerencia de ventas. El documento guía de forma cualitativa al usuario a través del tablero visual para la comprensión general

del flujo de conversión y el comportamiento de las campañas comerciales. Adicionalmente, proporciona pautas procedimentales para la priorización diaria de carteras utilizando la métrica de percentil como indicador relativo de orden de contacto e instruye en la interpretación de los clústeres para adaptar el discurso de ventas según las características demográficas de cada segmento.

4. **Manual de auditoría y documentación de componentes (*Componentes y Código*)** (Anexo J)**:** Diseñado como un manual técnico avanzado y apéndice de auditoría para ingenieros de software o científicos de datos responsables del mantenimiento a largo plazo. El documento detalla la arquitectura modular del paquete `scoring_leads`, describiendo las entradas, lógica interna y salidas de sus siete módulos específicos de Python y sus tres archivos de modelo congelados. Asimismo, detalla el funcionamiento de la batería de doce pruebas unitarias automatizadas que validan la robustez matemática del paquete (contrato de datos) frente a datos nulos, ruidosos o atípicos antes de compilar o actualizar el sistema.

Capítulo 8

Resultados y Discusión

8.1. Proceso comercial y gestión de leads

El proceso de administración de leads de la empresa inmobiliaria se formalizó mediante un modelo en la notación estándar de modelado de procesos de negocio (*BPMN*). Este modelo se estructuró dentro de una única entidad organizacional (*Empresa Inmobiliaria*) y se delimitó en tres carriles de responsabilidad: el asistente comercial, el sistema CRM y el asesor comercial.

El flujo comienza con la recepción del lead en el sistema y se desarrolló a través de un macroflujo unificado (Figura 8.1) que integró actividades globales de la organización, compuertas de decisión intermedias, envíos automáticos de mensajería y tres subprocesos modulares específicos (Figura 8.2, Figura 8.3 y Figura 8.4):

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.1: Macroflujo unificado del proceso comercial

Fuente: elaboración propia.

1. **Ingreso y recepción del lead:** El flujo inicia formalmente con la llegada del prospecto. Si el contacto provino de una campaña digital, el CRM registra los datos automáticamente. En caso contrario, el asistente comercial ejecuta el ingreso manual de la información en la plataforma.
2. **Subproceso de validación y asignación del lead:** Tras el registro del prospecto, se da inicio al primer subproceso modular, en el cual se valida la duplicidad de la información de contacto. Si se identifica un registro duplicado, el sistema elimina el registro para proteger la integridad de la base de datos; si el contacto era único, se asigna formalmente a un asesor comercial (ver Figura 8.2).

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.2: Subproceso: validar y asignar lead

Fuente: elaboración propia.

3. **Acciones de envío automatizado (Etapa intermedia):** Al concluir la asignación, se realiza el envío de información general por correo electrónico y por medio de la plataforma de WhatsApp.
4. **Subproceso de ejecución del proceso de contacto:** Inmediatamente después de los envíos, se activa el segundo subproceso modular. El asesor comercial lleva a cabo una secuencia estructurada de contacto, consistiendo en una llamada de perfilamiento inicial y hasta tres intentos adicionales

de llamada en caso de no obtener respuesta. Los ciclos posteriores de contacto incluyen mensajes de seguimiento por WhatsApp y se realizan con intervalos de 24 a 48 horas. Si el lead responde, se marca el fin del subproceso con éxito; si se agotan todos los intentos de comunicación sin recibir respuesta, el lead se registra como perdido en el sistema (ver Figura 8.3).

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.3: Subproceso: ejecutar proceso de contacto

Fuente: elaboración propia.

5. **Perfilamiento y calificación de interés (Etapa intermedia):** Una vez concluido el proceso de contacto, el macroflujo evalúa el resultado de la comunicación. Si no es posible contactar al lead, se registra el motivo de pérdida correspondiente. Si se establece el contacto, el asesor procede a perfilar al cliente potencial, el CRM cambia el estado a "Interesado" y se determina si el prospecto califica para el proyecto de acuerdo con su perfil y capacidad de compra. Si califica, el asesor le propone una visita al proyecto residencial. En caso de no calificar, el lead se registra como perdido bajo el motivo de pérdida correspondiente. Si califica, pero no acepta la visita, el flujo también se desvía hacia el registro de pérdida.
6. **Subproceso de gestión de la visita al proyecto:** Si el prospecto acepta la propuesta, se inicia el tercer subproceso modular. El asesor agenda la cita en el sistema y el CRM cambia el estado de la oportunidad a "Visita Programada". Al llegar el día agendado, si el cliente asiste, el asesor comercial lo atiende en el desarrollo habitacional y el proceso continúa hacia las etapas posteriores del flujo comercial (ver Figura 8.4).

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.4: Subproceso: gestionar visita al proyecto

Fuente: elaboración propia.

7. **Fase final de cierre y reserva (Etapa intermedia):** Una vez realizada la visita, el flujo continúa a través de las etapas posteriores del proceso comercial:
   - El estado cambia a "Visita Modelo" en el CRM y se brinda seguimiento posterior a la visita.
   - Conforme la oportunidad avanza hacia el cierre, el estado cambia a "Corto Plazo".
   - Al concretarse la reserva de la vivienda, el estado cambia a "Reserva" en el CRM, se inicia el proceso de reserva y el trato se transfiere al área de formalización comercial.

El diagrama expandido completo integra las interacciones entre los distintos carriles de responsabilidad y se presenta a página completa en el Anexo A por razones de legibilidad.

8.1.1. Identificación de puntos críticos y hallazgos del proceso

A partir del análisis del modelo BPMN se identificaron puntos críticos y hallazgos relevantes para caracterizar la estructura del proceso, las dinámicas que determinan el avance de los prospectos y la generación progresiva de información dentro del embudo comercial.

1. **Progresión del lead a través de etapas comerciales definidas:** El proceso presenta una estructura secuencial en la que el lead transita por estados que representan distintos niveles de avance comercial,

entre ellos “Contactado”, “Interesado”, “Visita Programada”, “Visita Modelo”, “Corto Plazo” y “Reserva”. Esta estructura evidencia que la conversión no ocurre como un evento aislado, sino como el resultado de una progresión dentro del embudo, en la que el prospecto atraviesa diferentes instancias de contacto, evaluación y seguimiento antes de concretar la oportunidad comercial. La existencia de estos estados permite, además, distinguir operacionalmente el grado de avance alcanzado por cada lead.

2. **Interacción entre el sistema CRM y la intervención humana:** La administración del lead distribuye actividades entre el sistema CRM y el equipo comercial. El CRM funciona como soporte para el registro y gestión de la información del prospecto y de su avance dentro del embudo, mientras que las principales interacciones comerciales requieren intervención humana. En particular, el asesor comercial realiza las llamadas de contacto, el perfilamiento y la calificación del prospecto, el seguimiento, la gestión de visitas y las actividades orientadas al cierre. Por su parte, el asistente comercial interviene en el ingreso, validación y asignación de los leads cuando corresponde. Esta distribución de responsabilidades evidencia que la administración de leads se desarrolla mediante la interacción entre el soporte tecnológico del CRM y la gestión directa del equipo comercial.

3. **Disponibilidad progresiva de información a lo largo del embudo:** La información disponible sobre un lead no permanece constante durante el proceso, sino que aumenta conforme se producen nuevas interacciones comerciales. En las primeras etapas se dispone principalmente de la información obtenida durante su captación. Una vez establecido el contacto, el perfilamiento incorpora datos adicionales sobre las características, intereses y capacidad de compra del prospecto. Conforme la oportunidad continúa avanzando, se generan nuevos registros asociados con su gestión comercial y, posteriormente, con la transacción y el proceso de formalización. En consecuencia, los campos almacenados en el CRM representan información generada en distintos momentos del recorrido comercial y no un conjunto de datos disponible de manera simultánea desde el ingreso del lead.

4. **La reserva como punto de concreción de la oportunidad comercial:** Dentro de la secuencia identificada, la etapa de “Reserva” constituye una frontera operacional entre la administración de la oportunidad comercial y el proceso posterior de formalización. Alcanzar esta etapa implica que el prospecto avanzó a través del embudo hasta concretar la reserva de una vivienda, después de lo cual el trato continúa hacia actividades propias de formalización. Por tanto, la reserva proporciona un punto observable dentro del proceso para delimitar la conversión de un lead, en correspondencia con la operación comercial de la empresa.

8.1.2. Embudo comercial

La Figura 8.5 muestra el volumen alcanzado en cada etapa y la tasa de progresión respecto de la etapa anterior.

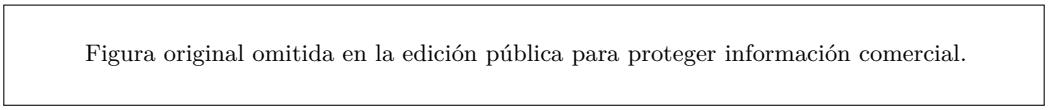


Figura 8.5: Volumen de leads y tasa de progresión por etapa del embudo comercial

Fuente: elaboración propia.

De los 437.6 miles de leads ingresados, 272.2 miles alcanzaron el estado “Contactado” (62 %). Solo 49.9 miles llegaron a “Interesado”, lo que corresponde a una progresión del 18 % entre ambas etapas y constituye la mayor contracción relativa del embudo. Después de ese punto, el 85 % de quienes programaron una visita llegó a la visita al modelo y el 93 % de quienes alcanzaron “Corto Plazo” llegó a “Reserva”. Entre “Visita Modelo” y “Corto Plazo” la progresión fue del 30 %.

8.1.3. Razones de pérdida registradas

El CRM contenía un motivo de pérdida para 423,656 leads. Las quince categorías de mayor volumen se presentan en el Cuadro 8.1.

Tabla 8.1: Principales motivos de pérdida de leads por volumen absoluto

Razón de pérdida	**Leads**
Varias llamadas y/o WhatsApp sin respuesta o sin avance	53,917
No le interesa y no dio una razón al respecto	48,945
No califica por ingresos	48,872
Varias llamadas y/o WhatsApp sin respuesta	45,393
Seguimiento constante sin ninguna señal de progreso	36,214
Información incorrecta del contacto	32,655
Cliente informa que verá la información y que se comunicará si tiene interés	27,642
Relación precio/cuota no le favorece	21,638
No solicitó información	20,132
Quería información por curiosidad	19,273
Características y/o ubicación del proyecto	12,647
Decidió invertir en otro proyecto	9,255
Busca renta de una propiedad	7,479
Postergó su decisión entre 3 y 6 meses	7,348
No se tiene número telefónico ni señal de interés	5,394
Otras razones (categorías con menos de 4,800 casos cada una)	26,852
Total con motivo de pérdida registrado	**423,656**

Fuente: elaboración propia.

Cinco categorías asociadas con imposibilidad de contacto o falta de avance en la comunicación sumaron 173,573 casos, equivalentes al 41.0 % de los descartes con motivo registrado. Este grupo incluye llamadas o mensajes sin respuesta o sin avance (53,917), llamadas o mensajes sin respuesta (45,393), seguimiento sin señal de progreso (36,214), información incorrecta de contacto (32,655) y ausencia de número telefónico o de señal de interés (5,394). En comparación, la falta de capacidad financiera y una relación precio–cuota desfavorable acumularon 70,510 casos, el 16.6 %.

La segunda categoría individual de mayor volumen fue "No le interesa y no dio una razón al respecto", con 48,945 registros. Estos casos confirman que la interrupción del proceso no responde a un único mecanismo: algunos leads no pudieron ser contactados, otros no calificaron y en un grupo numeroso hubo comunicación, pero el motivo de desinterés no quedó especificado.

La diversidad de motivos sugiere que la pérdida de un lead difícilmente puede explicarse a partir de una sola característica observable. En este contexto, la priorización puede beneficiarse de un enfoque que considere conjuntamente las distintas características disponibles del prospecto y de su origen para estimar su propensión a convertirse.

8.1.4. Disponibilidad de información

La información registrada en el CRM se incorpora progresivamente conforme el lead avanza en el proceso comercial. Los datos asociados con su origen, como el canal y la campaña de captación, están disponibles desde su ingreso. En cambio, variables de perfil como razón de compra, ingresos, composición familiar u opciones visitadas dependen de la información obtenida durante la interacción con el prospecto. Finalmente, los datos vinculados con la transacción y la unidad seleccionada aparecen en etapas posteriores del proceso.

Esta disponibilidad progresiva muestra que el perfil registrado de un lead no es estático, sino que se completa durante la gestión comercial. En consecuencia, la cantidad y el tipo de información disponible también reflejan, en cierta medida, el nivel de interacción alcanzado con el prospecto. Este comportamiento adquiere relevancia posteriormente en el modelado, donde la ausencia de algunas variables presentó capacidad predictiva.

8.2. Estructuración del conjunto de datos

8.2.1. Consolidación del historial

Los tres cortes de datos recibidos (C_1, C_2 y C_3) presentaron algunas inconsistencias en las fechas; tras la homologación, su consolidación permitió reunir 442,436 observaciones antes del control global de duplicados. Como muestra el Cuadro 8.2, únicamente 4,788 registros fueron excluidos posteriormente, equivalentes al 1.08 % del total integrado.

Tabla 8.2: Trazabilidad de registros durante la consolidación y depuración de los datos

Etapa	**Registros**	**Variación**
Registros procedentes de las fuentes integradas	442,436	–
Después de resolver identificadores repetidos	441,908	−528
Después de excluir desenlaces no determinables	437,767	−4,141
Después de validar el intervalo de edad	437,648	−119

Fuente: elaboración propia.

La mayor exclusión correspondió a 4,141 registros cuyo desenlace no podía determinarse de manera consistente porque la etapa y el estado de cierre proporcionaban lecturas incompatibles. Asignar esos casos a una de las dos clases habría incorporado una definición incierta de la variable objetivo. La tasa de conversión que se utiliza en los análisis posteriores corresponde, por tanto, a los registros con desenlace verificable.

Después de la depuración quedaron 437,648 registros y 5,144 reservas, una tasa de conversión del 1.18 %. Esta frecuencia hace inadecuada la exactitud como criterio principal de evaluación: clasificar todos los casos como no conversión produciría un 98.8 % de aciertos sin identificar una sola reserva.

Los seis proyectos permanecieron representados en el conjunto de datos, aunque con diferencias amplias en el número de registros (Cuadro 8.3). proyecto04 y proyecto02 concentraron la mayor parte de las observaciones, mientras que proyecto05 y proyecto06 tuvieron una representación considerablemente menor.

Tabla 8.3: Distribución de registros por proyecto residencial después de la depuración

Proyecto	**Registros**
proyecto04	177,630
proyecto02	124,683
proyecto01	71,247
proyecto03	41,452
proyecto06	16,680
proyecto05	5,956
Total	**437,648**

Fuente: elaboración propia.

8.2.2. Disponibilidad de variables para el modelado

De las 100 columnas originales, 54 se excluyeron del conjunto destinado al entrenamiento. El Cuadro 8.4 resume los motivos.

Tabla 8.4: Diagnóstico de las columnas del CRM según su viabilidad para el modelado

Situación diagnosticada	**Columnas**
Ausencia extrema de información o indisponibilidad en etapas tempranas	34
Fuga potencial de información posterior al desenlace (*data leakage*)	13
Alta omisión y contenido financiero parcialmente redundante	4
Redundancia estructural o ausencia de variabilidad	2
Sustitución del rango categórico de edad por la edad continua	1
Columnas excluidas	**54**
Columnas conservadas para las etapas posteriores del procesamiento	46
Total de columnas auditadas	**100**

Fuente: elaboración propia.

Treinta y cuatro columnas presentaban ausencia extrema o no existían en las etapas tempranas del proceso. Entre ellas se encontraban variables financieras como monto de préstamo, precio de venta, valor del bien y enganche pactado, con más del 99 % de valores faltantes. El mapeo del proceso mostró que estos campos se completan en fases posteriores a la reserva. Aunque su contenido podría estar relacionado con la compra, no estaban disponibles en el momento en que debe ocurrir la priorización y, por esa razón, no podían utilizarse como predictores tempranos.

Otras 13 columnas registraban información posterior al desenlace, entre ellas la etapa alcanzada, razones de pérdida, fechas de cierre, asignaciones de apartamento, parqueo y bodega, minutas y encuestas de satisfacción. Parte de estos campos fue necesaria para reconstruir la variable objetivo, pero mantenerlos en el entrenamiento habría permitido que el modelo utilizara consecuencias de la conversión para predecirla. Se conservaron para auditoría y trazabilidad, separados de las entradas del modelo.

Los campos de disponibilidad, rango de disponibilidad, moneda de disponibilidad y cuota deseada presentaban entre 90.95 % y 95.72 % de valores faltantes y aportaban información financiera parcialmente cubierta por el ingreso familiar, que tenía mayor disponibilidad. Asimismo, se conservó la edad continua en lugar del rango categórico: la primera estaba disponible en el 10.3 % de la base y el segundo en el 7.6 %, y la medida continua permitía construir agrupaciones posteriores sin perder granularidad.

La base depurada se amplió con 14 variables derivadas o provenientes de fuentes externas, sin modificar los 437,648 registros. Nueve describen características geográficas y comerciales de los proyectos; cuatro descomponen información de campaña y perfil; y una identifica la procedencia de cada fila. Cuando no existía una referencia externa equivalente para un proyecto, el valor se mantuvo como faltante. El diccionario de las 62 variables resultantes se incluye en el Anexo B.

Tabla 8.5: Clasificación del catálogo de 62 variables según su rol en el modelado

Rol	**Grupo de información**	**Estado de modelado**	**Variables**
Variable objetivo	Variable objetivo	Variable de salida (conversión)	1
Identificador	Identificadores	Excluido (identificadores técnicos)	3
Control	Control e indicadores	Excluido (trazabilidad administrativa)	3
Atributo de proyecto	Enriquecimiento de proyecto	Candidato (geografía y mercado)	9
Atributo de proyecto	Proyecto	Candidato (identidad del proyecto)	1
Atributo del lead	Perfil del lead	Candidato (demografía declarada)	10
Atributo del lead	Captación y canal	Candidato (origen del lead)	4
Atributo del lead	Comportamiento e interés	Candidato (interacción inicial)	2
Atributo del lead	Temporal	Candidato (fecha de creación del trato)	1
Variable derivada	Derivadas de campaña	Candidato (marketing digital)	3
Variable derivada	Derivadas de perfil	Candidato (rango de edad)	1
Postventa	Datos de postventa y trato	Excluido (fuga y omisión extrema)	24
Total			**62**

Fuente: elaboración propia.

El Cuadro 8.5 resume la composición del catálogo final: 31 predictores candidatos de disponibilidad temprana, 30 variables excluidas del entrenamiento por identificación, control o generación tardía, y una variable objetivo. Esta separación distingue la información útil para describir retrospectivamente el proceso de aquella que puede utilizarse para estimar conversión antes del desenlace.

Las variables de captación presentaron niveles muy distintos de dispersión entre categorías. `canal_de_anuencia` reunió 31 valores distintos, 32 al considerar la ausencia como una categoría, y 1,594 registros sin información. En cambio, `campania` presentó 421 denominaciones distintas, 422 al incluir la ausencia, además de 98,756 valores faltantes. Esto muestra que el nombre completo de la campaña estaba mucho más fragmentado que la información general sobre el canal de procedencia.

8.2.3. Completitud de la información

Las variables de perfil no estaban completas de manera uniforme. El Cuadro 8.6 muestra el efecto de exigirlas de forma acumulada sobre los 437,648 registros de la base consolidada completa.

Tabla 8.6: Embudo de completitud acumulada sobre la base consolidada completa

Paso	Variable exigida (acumulada)	Ausencia propia	N acumulado	Conversiones
1	`fuente_pt2`	0.0 %	437,648	5,144
2	`canal_de_anuencia`	0.4 %	436,054	3,753
3	`canal_de_contacto`	0.2 %	435,141	3,753
4	`sexo`	56.4 %	189,664	3,547
5	`ingreso_familiar`	67.2 %	62,141	3,230
6	`razon_de_compra`	20.9 %	49,161	3,203
7	`estado_civil`	17.3 %	40,680	3,164
8	`edad`	12.2 %	35,716	3,130
9	`nucleo_familiar`	26.1 %	26,400	3,031
10	`tiene_hijos`	14.8 %	22,482	2,588

Fuente: elaboración propia.

El embudo evidencia que la mayor reducción del universo ocurre al incorporar las variables de perfil. Después de exigir los dos campos de canal permanecen 435,141 registros; la adición de `sexo` reduce el conjunto a 189,664 y la de `ingreso_familiar` lo lleva a 62,141. Estos dos pasos concentran la mayor pérdida de observaciones y muestran que la información demográfica y económica se registró con mucha menor frecuencia que los datos básicos de procedencia y contacto.

Al exigir de forma acumulada las diez variables, la base disminuye de 437,648 a 22,482 registros: se conserva únicamente el 5.14 % de las observaciones originales. La reducción de las conversiones es considerablemente menor, pues permanecen 2,588 de las 5,144 reservas, equivalentes al 50.31 %. Por ello, la tasa de conversión aumenta del 1.18 % en la base consolidada completa al 11.51 % en el subconjunto con información completa.

Esta diferencia mostró que exigir información completa no constituía únicamente una reducción del tamaño de la muestra, sino que alteraba la composición del conjunto al retener proporcionalmente más leads convertidos. Por esta razón, se descartó el uso de casos completos como criterio para definir la población de modelado. En su lugar, se conservaron observaciones con datos faltantes en variables de perfil y se evaluó su ausencia como parte de la información disponible para el modelo. Esta decisión permitió ampliar posteriormente el universo de modelado sin restringirlo a los leads con mayor nivel de completitud.

8.2.4. Universos de modelado

De los 437,648 registros consolidados, 45,614 correspondieron a leads que habían alcanzado al menos la etapa “Interesados”. Dentro de esta población se registraron 870 conversiones, equivalentes a una tasa del 1.91 %. Este conjunto constituyó la base de leads calificados a partir de la cual se definieron los universos utilizados en el modelado.

Los resultados del análisis de completitud mostraron que exigir información en las diez variables habría reducido esta población a 15,200 leads y 672 conversiones (Véase Anexo C). Al aplicar requisitos diferenciados

de completitud, el Universo H quedó conformado por 22,656 leads y 739 conversiones, con una tasa base del 3.26 %. En comparación con el criterio de casos completos, esta definición permitió conservar 7,456 leads y 67 conversiones adicionales, incrementos del 49.1 % y 10.0 %, respectivamente.

La segmentación requirió un universo distinto debido a las variables utilizadas para conformar los conglomerados. El Universo S reunió 20,647 leads y 731 conversiones, con una tasa de conversión del 3.54 %. El Cuadro 8.7 resume la composición final de los conjuntos utilizados en ambos análisis.

Tabla 8.7: Universos de análisis derivados del extracto consolidado

Universo	**Criterio de completitud**	**N**	**Conv.**	**Tasa**
Base CRM consolidada	–	437,648	5,144	1,18 %
Leads calificados	etapa $\geq$ «Interesados»	45,614	870	1,91 %
Casos completos (referencia)	las 10 variables de perfil	15,200	672	4,42 %
Universo H (predictivo)	`fuente_pt2`, dos canales, `ingreso_familiar`, `edad`	22,656	739	3,26 %
Universo S (segmentación)	`edad`, `sexo`, `estado_civil`, `razon_de_compra`, `tipo_unidad`	20,647	731	3,54 %

Fuente: elaboración propia.

8.2.5. Análisis exploratorio

Conversión y volumen por canal de anuencia

Las mayores tasas de conversión se observaron en canales de acceso restringido o con poblaciones pequeñas: compras corporativas o de socios (97.92 %), OpenSale (92.45 %), referidos de clientes y colaboradores (87.96 %) y eventos de lanzamiento (53.33 %), como se muestra en la Figura 8.6.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.6: Tasa de conversión de leads por canal de anuencia comercial

Fuente: elaboración propia.

Estas tasas no coincidieron con los canales que aportaron más conversiones en términos absolutos. Los canales anteriores sumaron alrededor de 200 reservas, mientras que Facebook concentró aproximadamente 1,200 reservas, las referencias unas 600 y los canales de referidos directos y sede unas 400 cada uno (Figura 8.7).

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.7: Volumen absoluto de conversiones por canal de anuencia comercial

Fuente: elaboración propia.

Los canales con las tasas de conversión más altas no coincidieron necesariamente con los que generaron la mayor cantidad de reservas. Algunos canales de menor volumen presentaron tasas excepcionalmente elevadas, mientras que canales con tasas más moderadas concentraron un número considerablemente mayor de conversiones debido a la cantidad de leads que aportaron. Este contraste muestra que el desempeño de un canal no puede interpretarse únicamente a partir de su tasa de conversión: el volumen de leads también determina su contribución al resultado comercial.

La coexistencia de canales con perfiles tan distintos también evidencia que la procedencia del lead contiene información relevante sobre su comportamiento dentro del embudo. Más adelante, esta señal volvió a aparecer

en el modelo predictivo, donde las variables asociadas con el origen del prospecto se ubicaron entre las de mayor importancia.

Razón de compra

Los leads que declararon una motivación de inversión presentaron una tasa de conversión del 10.64 %, frente al 3.20 % de quienes declararon compra para vivienda. La diferencia supera siete puntos porcentuales y fue el contraste más amplio entre los atributos declarados del prospecto analizados de forma bivariada.

Este resultado muestra que la razón de compra permite distinguir perfiles con comportamientos de conversión considerablemente diferentes. En particular, los leads interesados en adquirir una propiedad como inversión presentaron una mayor propensión a alcanzar la reserva que quienes buscaban una vivienda para uso propio.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.8: Tasa de conversión de leads según la razón de compra declarada

Fuente: elaboración propia.

Edad

La tasa de conversión aumentó con la edad: 3.5 % entre los menores de 28 años, 6.0 % entre 28 y 34, 8.3 % entre 35 y 45, 8.4 % entre 46 y 52, 11.3 % entre 53 y 60 y 11.7 % entre los mayores de 60 (Figura 8.9).

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.9: Volumen de leads y tasa de conversión por rangos de edad

Fuente: elaboración propia.

El patrón fue consistente a lo largo de los rangos analizados: los leads de mayor edad presentaron tasas de conversión progresivamente más altas. Sin embargo, el volumen se concentró principalmente entre los 28 y 45 años, mientras que los grupos con las mayores tasas tuvieron una participación menor en la base. La edad mostró, por tanto, diferencias claras en la conversión observada entre los distintos perfiles del prospecto.

Otras variables demográficas

La tasa de conversión fue del 2.33 % entre hombres y del 1.41 % entre mujeres, con una captación cercana a partes iguales. La presencia de hijos separó tasas del 10.4 % y del 8.4 %; el estado civil y el tamaño del núcleo familiar no mostraron patrones definidos una vez consideradas sus categorías. Los resultados completos se incluyen en el Anexo E.

Comportamiento temporal

Entre agosto de 2017 y abril de 2026 no se observó un patrón estacional de calendario estable. Los meses de mayor afluencia coincidieron con períodos de superposición de pautas de varios proyectos, mientras que la tasa mensual de conversión permaneció baja y relativamente estable, incluso durante los aumentos de captación. La evidencia gráfica se incluye en el Anexo E.

La coincidencia con las pautas no permite atribuir toda la variación del volumen a las campañas ni descartar por completo cambios temporales en la demanda. Sí indica que el historial disponible no contenía una señal de calendario estable que justificara utilizar el mes o la temporada como predictores principales.

8.3. Modelo predictivo y segmentación de leads

8.3.1. Modelo predictivo de conversión

Selección del Universo

La regresión logística seleccionada como modelo final presentó un desempeño superior al obtenido en la fase preliminar. El Cuadro 8.8 muestra la comparación entre ambas configuraciones.

Tabla 8.8: Comparación entre la configuración previa y el modelo final

Indicador	Configuración previa	Modelo final
Universo de entrenamiento	casos completos	Universo H
(tamaño)	13,038 leads†	22,656 leads
PR-AUC	≈0.07	0.2215
Leads requeridos para *recall*≥0.70	64.2 %	29.1 %
Precisión en ese punto	5.1 %	7.9 %
Lift en el primer decil	≈2.6	4.15

Fuente: elaboración propia.

† Tamaño sobre el extracto preliminar del proyecto; el análisis de completitud sobre la base consolidada completa se presenta en el Cuadro 8.6.

El modelo final alcanzó un PR-AUC de 0.2215, frente a aproximadamente 0.07 en la configuración preliminar. La diferencia también se reflejó en la capacidad de concentrar las conversiones: para alcanzar un *recall* de al menos 70 %, la proporción de leads que debía priorizarse se redujo de 64.2 % a 29.1 % del universo correspondiente. Al mismo tiempo, la precisión en ese punto aumentó de 5.1 % a 7.9 % y el *lift* del primer decil pasó de aproximadamente 2.6 a 4.15.

En términos operativos, el modelo final permitió identificar al menos siete de cada diez conversiones priorizando menos de un tercio de los leads. Este resultado representa una mejora relevante para el objetivo de priorización, ya que concentra una mayor proporción de las conversiones en un grupo considerablemente menor de prospectos. La Sección 8.4.3 traduce estas métricas a términos de esfuerzo comercial.

El conjunto del trabajo evaluó 489 configuraciones modeladas de predicción. El registro completo, con las variables de cada lote, se presenta en el Anexo F.

Selección del algoritmo

La Figura 8.10 muestra que varias familias alcanzaron valores competitivos de PR-AUC, aunque con una variación considerable entre las configuraciones evaluadas dentro de cada una. La regresión logística se ubicó entre los algoritmos con mejor desempeño, mientras que los métodos basados en árboles y el perceptrón multicapa no produjeron una mejora consistente frente a los modelos lineales.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.10: PR-AUC por familia de algoritmo en la búsqueda exhaustiva del modelo predictivo

Fuente: elaboración propia.

La comparación más cercana se produjo entre la regresión logística y el análisis discriminante lineal (LDA). Antes del ajuste de hiperparámetros y sobre el mismo conjunto base de variables, el análisis discriminante alcanzó un PR-AUC de 0.2160, frente a 0.2041 de la regresión logística. Sin embargo, esta diferencia no se reprodujo en las métricas orientadas directamente a la priorización: en el primer decil, la regresión logística alcanzó un *recall* de 0.3677 y un *lift* de 3.68, superiores al 0.3552 y 3.55 obtenidos por el análisis discriminante. Después del ajuste de hiperparámetros, la relación también se invirtió en PR-AUC, con 0.2204 para la regresión logística y 0.2178 para el análisis discriminante.

Estos resultados favorecieron la selección de la regresión logística sin requerir un sacrificio de desempeño predictivo. Además de alcanzar el mayor PR-AUC entre ambas alternativas después del ajuste, presentó mejores resultados de priorización en el primer decil.

Las estrategias de tratamiento del desbalance tampoco produjeron mejoras consistentes. El sobremuestreo sintético modificó el PR-AUC entre 0.002 y 0.005, con variaciones tanto positivas como negativas según la configuración, mientras que el submuestreo aleatorio lo redujo aproximadamente 0.02. Por esta razón, el modelo final conservó la distribución original de las clases.

Coeficientes del modelo

La probabilidad estimada se obtiene mediante la siguiente función:

$$P(\text{conversión}) = \frac{1}{1+e^{-z}}, \qquad z = \beta_0 + \sum_{i=1}^{p} \beta_i x_i \tag{8.1}$$

con intercepto $\beta_0 = -1.9577$. Los términos de mayor magnitud absoluta se presentan en el Cuadro 8.9; el listado completo se encuentra en el Anexo I.

Tabla 8.9: Coeficientes de mayor magnitud del modelo final

Término	**Coeficiente**
`canal_de_anuencia = Referencia`	−1.9124
`canal_de_contacto` (categorías agrupadas)	+1.8356
`opciones_visitadas = _missing_`	−1.5828
`participantes_en_credito = _missing_`	−1.2080
`campania_tipo = footer`	+0.9628
`estado_civil = _missing_`	−0.9310
`razon_de_compra = _missing_`	−0.8512
`canal_de_contacto = Visita Inédita`	−0.8307
`tipo_unidad = 2 Habs`	−0.8253
`canal_de_anuencia` (categorías agrupadas)	+0.8039

Fuente: elaboración propia.

Los coeficientes de mayor magnitud muestran que la estimación de conversión se apoyó principalmente en características relacionadas con el origen del lead, su canal de contacto y la información recopilada durante la gestión comercial. Entre los términos con coeficientes positivos destacan las categorías agrupadas de `canal_de_contacto` (+1.8356), `campania_tipo = footer` (+0.9628) y las categorías agrupadas de `canal_de_anuencia` (+0.8039). En conjunto, estos resultados muestran que la forma en que el prospecto ingresó y fue contactado aportó información relevante para diferenciar su probabilidad estimada de conversión.

Otro resultado relevante es la presencia de valores faltantes en cuatro de los diez términos de mayor magnitud. La ausencia de información en `opciones_visitadas`, `participantes_en_credito`, `estado_civil` y `razon_de_compra` estuvo asociada con menores probabilidades estimadas de conversión. El patrón sugiere que el nivel de información disponible sobre un lead también distingue perfiles con diferente comportamiento de conversión, por lo que la ausencia de datos constituyó una señal aprovechada por el modelo y no únicamente una condición de incompletitud del registro.

Ausencia de información en el modelo

Cuatro de los diez coeficientes de mayor magnitud correspondieron a valores faltantes. La ausencia de información en `opciones_visitadas` (−1.58), `participantes_en_credito` (−1.21), `estado_civil` (−0.93) y `razon_de_compra` (−0.85) estuvo asociada con una menor probabilidad estimada de conversión. La recurrencia del mismo patrón en variables distintas muestra que el grado de información registrado sobre un lead también aportó elementos para su priorización.

Este resultado adquiere especial relevancia frente al análisis de completitud presentado anteriormente. La exclusión de registros incompletos habría reducido el universo disponible y eliminado conversiones reales; al conservar estos registros y representar explícitamente la ausencia, el modelo pudo utilizar las diferencias en

completitud como parte de la información disponible para distinguir entre leads. De esta manera, los valores faltantes no se limitaron a reducir la cantidad de información disponible, sino que también formaron parte de los patrones identificados por el modelo. Este patrón podría estar relacionado con la incorporación progresiva de información durante la gestión comercial, ya que varios de estos campos se completan conforme avanza la interacción con el prospecto.

Identidad del proyecto

Al incorporar la identidad del proyecto y la fuente como predictores adicionales, manteniendo las mismas 22,656 observaciones y el mismo procedimiento de validación, el PR-AUC aumentó de 0.2215 a 0.2333 y el *lift* del primer decil de 4.15 a 4.32. La diferencia de 0.0118 en PR-AUC equivale a una mejora relativa del 5.3 % respecto del modelo final.

El incremento muestra que la identidad del proyecto contiene información asociada con la conversión. Sin embargo, esta información proviene del comportamiento histórico de cada desarrollo: el modelo puede aprender, por ejemplo, que los leads de determinados proyectos han convertido con mayor frecuencia que los de otros. Aunque esta señal mejora la predicción sobre los proyectos observados, depende de contar con antecedentes del mismo desarrollo.

Por esta razón, la identidad del proyecto no se incorporó al modelo final. Su exclusión permite que la priorización se base en características del lead, su procedencia y la información disponible durante la gestión comercial, en lugar de depender del desempeño histórico del proyecto al que pertenece. La reducción relativamente pequeña del PR-AUC, de 0.2333 a 0.2215, muestra el costo predictivo de esta decisión y permite cuantificar el desempeño que se dejó de capturar al prescindir de esa información.

8.3.2. Segmentación de leads

La segmentación mediante K-Means se estimó sobre el Universo S a partir de cinco variables de perfil: edad, sexo, estado civil, razón de compra y tipo de unidad. La conversión no intervino en la formación de los grupos. Se evaluaron 37 configuraciones de variables y 323 ajustes del algoritmo y se seleccionó la configuración R1, que identificó seis grupos y alcanzó un coeficiente de silueta de 0.517. El registro completo de estas configuraciones se presenta en el Anexo F, mientras que las métricas internas y los perfiles completos de los seis grupos se incluyen en el Anexo H.

Los grupos se diferenciaron principalmente por razón de compra, sexo y estado civil, mientras que la edad introdujo variación adicional y el tipo de unidad tuvo una participación menor en la separación. Esta estructura hace que los grupos puedan describirse a partir de atributos observables.

Perfil descriptivo de los grupos

El Cuadro 8.10 resume las características predominantes de los seis grupos y propone una denominación descriptiva para facilitar su interpretación. La razón de compra constituye la principal diferencia entre los perfiles identificados: cuatro grupos corresponden a leads interesados en adquirir vivienda (0, 2, 3 y 4), mientras que dos concentran a quienes declararon una motivación de inversión (1 y 5). Dentro de los perfiles orientados a vivienda aparecen diferencias adicionales por sexo, estado civil, edad y tipo de unidad. Los grupos 0 y 2 están conformados por mujeres y los grupos 3 y 4 por hombres, mientras que los grupos 2 y 3 presentan una mayor preferencia por unidades de tres habitaciones. Los dos grupos de inversión incluyen ambos sexos, aunque con predominio masculino, y se distinguen principalmente por la edad y el estado civil: el grupo 1 presenta una edad promedio de 45 años y predominio de personas casadas, frente a 36 años y predominio de personas solteras en el grupo 5.

Tabla 8.10: Perfil descriptivo de los seis grupos del modelo final

Grupo	Nombre	N	%	Edad	Sexo	Est. civil	Motivación	Unidad
0	Compradora independiente	3,562	17.3	35	F	Solter@	Vivienda	2 hab.
1	Inversionista consolidado	3,379	16.4	45	M	Casad@	Inversión	2 hab.
2	Compradora residencial consolidada	2,798	13.6	42	F	Casad@	Vivienda	3 hab.
3	Comprador familiar de mayor espacio	4,339	21.0	43	M	Casad@	Vivienda	3 hab.
4	Comprador joven de vivienda	4,004	19.4	34	M	Solter@	Vivienda	2 hab.
5	Inversionista emergente	2,565	12.4	36	M	Solter@	Inversión	2 hab.

Fuente: elaboración propia.

Los perfiles muestran que la cartera no constituye un conjunto homogéneo de prospectos. Incluso entre leads con una misma razón general de compra aparecen diferencias en edad, estado civil y preferencia de unidad que permiten distinguir perfiles comerciales más específicos. Esta caracterización aporta una segunda dimensión al análisis de la cartera: mientras el modelo predictivo establece una prioridad individual de atención, los grupos permiten describir las características predominantes de los prospectos que conforman esa cartera.

La Figura 8.11 proyecta las 20,647 observaciones sobre los dos primeros componentes principales de la matriz de segmentación, que explican en conjunto el 59.4 % de la varianza. La separación observada entre los seis grupos coincide con el coeficiente de silueta de 0.517 y muestra que los perfiles identificados presentan estructuras diferenciadas en las variables utilizadas para la segmentación.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.11: Proyección de los leads sobre los dos primeros componentes principales, coloreada por grupo

Fuente: elaboración propia.

La conversión se incorporó posteriormente al análisis para determinar si los perfiles identificados presentaban diferencias en su comportamiento comercial. Las tasas obtenidas se presentan en el Cuadro 8.11 y la Figura 8.12.

Tabla 8.11: Tasa de conversión por grupo, con intervalos de Wilson al 95 %

Grupo	N	Conv.	Tasa	IC 95 %	Lift	Clasificación
0	3,562	79	2.22 %	[1.78; 2.76]	0.63	Inferior
1	3,379	178	5.27 %	[4.56; 6.07]	1.49	**Superior**
2	2,798	63	2.25 %	[1.76; 2.87]	0.64	Inferior
3	4,339	126	2.90 %	[2.44; 3.45]	0.82	Inferior
4	4,004	127	3.17 %	[2.67; 3.76]	0.90	Sin diferencia
5	2,565	158	6.16 %	[5.29; 7.16]	1.74	**Superior**

Fuente: elaboración propia.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.12: Tasa de conversión por grupo con intervalos de confianza

Fuente: elaboración propia.

Los grupos 5 y 1, correspondientes a los perfiles inversionista emergente e inversionista consolidado, presentaron las mayores tasas de conversión, con 6.16 % y 5.27 %, respectivamente. Sus *lift* de 1.74 y 1.49 indican que ambos concentraron conversiones por encima de la tasa promedio del Universo S. En contraste, los cuatro grupos orientados a vivienda registraron tasas entre 2.22 % y 3.17 %. La diferencia observada reproduce, desde una caracterización multivariable de los prospectos, el patrón identificado previamente para la razón de compra: los perfiles asociados con inversión presentan una mayor propensión observada a alcanzar la reserva.

La comparación con el modelo predictivo permite delimitar el uso comercial de la segmentación. El grupo con mayor conversión alcanzó un *lift* de 1.74, considerablemente menor que el 4.15 obtenido por el primer decil del modelo predictivo. Por tanto, los grupos aportan mayor valor para caracterizar la composición de la cartera que para determinar qué leads individuales deben atenderse primero. En la práctica, ambos resultados cumplen funciones complementarias: el puntaje predictivo permite establecer la prioridad de atención de cada lead, mientras que el grupo al que pertenece aporta contexto sobre su perfil, motivación de compra y preferencia de unidad.

Esta combinación permite que la priorización comercial no se limite a identificar qué prospectos presentan mayor probabilidad estimada de conversión, sino que incorpore información sobre el tipo de prospecto que se encuentra detrás de esa prioridad. Para mercadeo y ventas, los perfiles pueden utilizarse como base para analizar estrategias diferenciadas de comunicación, oferta y seguimiento según las características predominantes de cada grupo. En particular, la distinción entre perfiles orientados a inversión y vivienda, así como las diferencias en preferencia de unidad, proporciona criterios para adaptar el contenido comercial sin sustituir la priorización individual producida por el modelo predictivo.

8.4. Evaluación del modelo predictivo

8.4.1. Discriminación y calibración

Las métricas calculadas sobre predicciones fuera de la partición de entrenamiento se presentan en el Cuadro 8.12.

Tabla 8.12: Métricas consolidadas del modelo final (*out-of-fold*)

Métrica	**Valor**
PR-AUC	0.2215
ROC-AUC	0.7958
Brier score	0.0282
Exactitud	0.7222
Exactitud balanceada	0.7119
F_1	0.1413
F_2 (ponderada a *recall*)	0.2713
MCC	0.1658
κ de Cohen	0.0878

Fuente: elaboración propia.

El modelo alcanzó un PR-AUC de 0.2215. En el Universo H, las conversiones representan el 3.26 % de los leads; por tanto, un ordenamiento sin capacidad predictiva mantendría, en promedio, una precisión cercana a 3.26 % a lo largo de la curva Precision–Recall. En consecuencia, el PR-AUC esperado bajo esta referencia es aproximadamente 0.0326, como se observa en la Figura 8.13. La diferencia entre esta referencia y el resultado obtenido muestra que el modelo logra concentrar una mayor proporción de conversiones entre los leads ubicados en las primeras posiciones del ordenamiento, lo que permite orientar el esfuerzo comercial hacia una fracción de la cartera con mayor presencia de prospectos que posteriormente alcanzan la reserva.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.13: Curva de precisión–*recall* del modelo final frente a la referencia sin capacidad discriminativa (Universo H)

Fuente: elaboración propia.

El ROC-AUC de 0.7958 indica que, al comparar un lead convertido con uno no convertido, el modelo asigna una puntuación mayor al convertido en aproximadamente ocho de cada diez pares. Este resultado confirma que el ordenamiento generado distingue de manera consistente entre leads con diferente resultado comercial. Sin embargo, debido a la baja proporción de conversiones en el Universo H, el PR-AUC resulta más informativo para evaluar la capacidad de concentrar precisamente los casos que interesa identificar.

El Brier score fue de 0.0282, frente a 0.0315 para una predicción que asignara a todos los leads la tasa base de conversión del Universo H. Esto representa una reducción del 10.5 % en el error cuadrático medio de las probabilidades estimadas. El resultado muestra que las probabilidades generadas por el modelo presentan un menor error respecto de los resultados observados que una predicción uniforme basada únicamente en la tasa general de conversión.

La exactitud del modelo fue de 72.2 %. Sin embargo, esta métrica resulta poco informativa de forma aislada debido al desbalance entre las clases: dado que el 96.7 % de los leads no alcanza la conversión, un clasificador que asignara todos los casos como no convertidos obtendría una exactitud cercana al 96.7 %, aun cuando no identificaría ninguna conversión. Por esta razón, una exactitud elevada no necesariamente representa un mejor desempeño para el objetivo de priorización. En este contexto, resulta más relevante evaluar qué proporción de las conversiones logra concentrar el modelo dentro de una fracción reducida de la cartera, aspecto que se examina mediante el *recall*, la ganancia acumulada y el *lift*.

La Figura 8.14 permite observar este comportamiento a distintos niveles de priorización. La curva de ganancia acumulada se mantiene por encima de la referencia aleatoria durante la mayor parte del recorrido, lo que muestra que ordenar los leads según el puntaje del modelo permite encontrar conversiones más rápidamente que atender la cartera sin diferenciación. El mismo patrón se refleja en el *lift*: la ventaja es mayor en los primeros cortes de la cartera y disminuye progresivamente conforme se incorporan leads con puntuaciones menores. Este comportamiento es consistente con el propósito operativo del modelo, ya que su mayor aporte se concentra precisamente en las primeras posiciones del ordenamiento.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.14: Curvas ROC, ganancia acumulada y *lift* por corte del modelo final (predicciones *out-of-fold*, Universo H)

Fuente: elaboración propia.

8.4.2. Importancia de variables

La importancia por permutación situó a `es_referido` como la variable con mayor contribución al desempeño predictivo: al permutar sus valores, el PR-AUC disminuyó en promedio 0.0786. Le siguieron `canal_de_contacto`, con una reducción de 0.0565, y `canal_de_anuencia`, con 0.0465. La interacción entre edad e ingreso ocupó la cuarta posición, con 0.0329, mientras que `es_inversion` presentó una importancia de 0.0166. La Figura 8.15 presenta los resultados para el conjunto de variables evaluadas.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.15: Importancia por permutación de las variables de entrada del modelo final, medida mediante la caída media de PR-AUC

Fuente: elaboración propia.

Las tres variables con mayor importancia corresponden a características relacionadas con la procedencia y la vía de llegada del prospecto. En conjunto, este resultado muestra que la información sobre cómo se originó el lead y cómo ingresó al proceso comercial aporta una señal particularmente relevante para su priorización. La diferencia respecto de las variables restantes también es considerable: la cuarta variable, correspondiente a la interacción entre edad e ingreso, produjo una reducción media de PR-AUC de 0.0329 al ser permutada.

Las características demográficas consideradas de forma individual mostraron una contribución considerablemente menor. La permutación de `edad_n`, `sexo` e `ingreso_familiar` produjo cambios cercanos a cero en el PR-AUC, mientras que la interacción entre edad e ingreso se ubicó entre las variables de mayor importancia. Este resultado indica que la información conjunta de ambas características aporta al modelo una señal predictiva que no se observa con la misma intensidad al evaluarlas individualmente.

8.4.3. Comparación con selección aleatoria

La simulación de Monte Carlo permitió comparar las conversiones concentradas por el ordenamiento del modelo con las que podrían obtenerse al seleccionar la misma cantidad de leads de forma aleatoria. Para obtener una referencia estable del comportamiento esperado bajo selección aleatoria, el análisis de alta resolución comprendió 1.6 millones de simulaciones, correspondientes a 200,000 repeticiones en cada uno de ocho niveles de capacidad. El Cuadro 8.13 presenta la comparación para los principales niveles de capacidad comercial.

Tabla 8.13: Conversiones capturadas por el modelo frente a selección aleatoria

Capacidad	**Leads**	**Modelo**	**Azar (media)**	**IC 95 % azar**	**Lift**	**Incremento**
5.0 %	1,133	223	36.96	[26; 49]	6.03	+503 %
10.0 %	2,266	307	73.91	[59; 90]	4.15	+315 %
14.3 %	3,234	370	105.49	[88; 124]	3.51	+251 %
19.9 %	4,498	444	146.72	[126; 168]	3.03	+203 %

Fuente: elaboración propia.

En todos los niveles de capacidad evaluados, el modelo concentró un número de conversiones superior al esperado mediante selección aleatoria. La diferencia fue particularmente amplia en las primeras posiciones del ordenamiento. Al considerar el 5.0 % de la cartera, equivalente a 1,133 leads, el modelo concentró 223 de las 739 conversiones, frente a una media de 36.96 bajo selección aleatoria. Esto significa que aproximadamente tres de cada diez conversiones existentes en el Universo H se encuentran dentro del primer 5.0 % del ordenamiento. Al ampliar la capacidad al 10.0 %, el número de conversiones concentradas aumentó a 307, equivalente al 41.5 % de todas las conversiones del universo.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.16: Posición del modelo dentro de la distribución de la selección aleatoria

Fuente: elaboración propia.

La Figura 8.16 muestra la magnitud de esta separación. En el corte correspondiente al 5.0 % de la cartera, ninguna de las 200,000 selecciones aleatorias alcanzó las 223 conversiones concentradas por el modelo; el

máximo observado fue de 63. La diferencia también se observó en los demás niveles de capacidad evaluados. En todos los casos, las primeras posiciones del ordenamiento concentraron más conversiones que las esperadas mediante una selección aleatoria de la misma cantidad de leads.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.17: Conversiones capturadas por el modelo y por selección aleatoria según la capacidad comercial

Fuente: elaboración propia.

Como muestra la Figura 8.17, la ventaja del modelo se mantiene al modificar la cantidad de leads que pueden ser atendidos. El *lift* fue de 6.03 en el primer 5.0 % de la cartera, 4.15 en el primer 10.0 % y 3.03 al considerar el 19.9 %. La disminución progresiva del *lift* muestra que la señal predictiva se concentra principalmente en las primeras posiciones: conforme aumenta la capacidad y se incorporan leads con puntuaciones menores, también disminuye la concentración de conversiones.

Los resultados muestran que el valor comercial del modelo se mantiene bajo distintos niveles de capacidad operativa. La ventaja relativa es mayor cuando la cantidad de leads que puede atenderse es reducida, debido a que las primeras posiciones del ordenamiento presentan la mayor concentración de conversiones. A medida que aumenta la capacidad disponible, el equipo comercial puede ampliar progresivamente la proporción de la cartera atendida siguiendo el mismo orden de prioridad. Aunque la concentración disminuye conforme se incorporan leads con puntuaciones menores, en todos los niveles evaluados el modelo mantuvo una ventaja frente a la selección aleatoria. De esta forma, el ordenamiento puede utilizarse con distintos niveles de capacidad y permite orientar el esfuerzo comercial hacia los leads con mayor puntuación dentro de los recursos disponibles.

La Figura 8.18 traduce esta concentración en términos de esfuerzo comercial. En la cartera completa del Universo H se observa, en promedio, una conversión por cada 31 leads. Al seguir el orden generado por el modelo, esta relación disminuye a 5 contactos por conversión cuando la capacidad permite priorizar el primer 5 % de la cartera y a 7 al considerar el primer 10 %. Incluso al ampliar la cobertura al 20 % y 30 % de la cartera, se requieren aproximadamente 10 y 13 contactos por conversión, respectivamente, valores todavía considerablemente inferiores a la referencia de la cartera completa.

La diferencia muestra que la priorización permite aprovechar con mayor eficiencia una capacidad comercial limitada. El beneficio es especialmente marcado en las primeras posiciones del ordenamiento, donde se requiere atender a un número menor de leads por cada conversión histórica concentrada. Conforme aumenta la capacidad, el equipo puede extender la atención hacia una proporción mayor de la cartera; aunque el esfuerzo requerido por conversión aumenta progresivamente, el ordenamiento mantiene una ventaja frente a una atención sin priorización.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.18: Contactos por conversión histórica según el porcentaje de la cartera priorizada

Fuente: elaboración propia.

La misma relación puede expresarse en términos de conversiones concentradas por cada 100 leads priorizados. Como muestra la Figura 8.19, en la cartera completa se observan aproximadamente 3.3 conversiones por cada 100 leads. Al concentrar la atención en las primeras posiciones del ordenamiento, esta relación aumenta a 19.7 conversiones por cada 100 leads en el primer 5 % de la cartera y a 13.5 en el primer 10 %. Incluso al ampliar la capacidad al 20 % y 30 % de la cartera, se mantienen aproximadamente 9.9 y 7.7 conversiones por cada 100 leads priorizados, respectivamente.

Esta lectura permite dimensionar el rendimiento asociado con distintos niveles de capacidad comercial. Un equipo con capacidad para atender una fracción reducida de la cartera puede concentrar su esfuerzo en grupos donde la presencia histórica de conversiones es considerablemente mayor que en el universo completo.

Conforme aumenta la cantidad de leads priorizados, la concentración disminuye progresivamente, pero permanece por encima de la tasa base en todos los niveles evaluados.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.19: Conversiones históricas por cada 100 leads priorizados según la capacidad comercial

Fuente: elaboración propia.

8.5. Implementación en Power BI

La implementación de los modelos se realizó mediante el paquete `scoring_leads`, integrado al flujo de datos utilizado en Power BI. Como muestra la Figura 8.20, el paquete recibe la tabla de leads, prepara las variables requeridas y ejecuta los componentes de segmentación y predicción. El resultado conserva la estructura de la tabla original e incorpora dos campos analíticos: `cluster`, que identifica el grupo asignado al lead cuando se dispone de la información requerida para la segmentación, y `percentil`, que expresa su prioridad relativa dentro de la cartera.

Figura original omitida en la edición pública para proteger información comercial.

Figura 8.20: Flujo de implementación de los modelos de segmentación y priorización

Fuente: elaboración propia.

La prioridad se expresó mediante percentiles para facilitar la lectura del ordenamiento generado por el modelo. En lugar de utilizar únicamente la probabilidad estimada de conversión, cada lead se ubica en una escala relativa de 0 a 100 según su posición respecto del resto de la cartera. Esta transformación conserva el orden establecido por el modelo y permite distinguir con mayor claridad los prospectos que ocupan las posiciones superiores, aun cuando sus probabilidades absolutas de conversión sean bajas.

La incorporación conjunta de `percentil` y `cluster` traslada los resultados de los dos componentes analíticos a una misma tabla. El percentil permite establecer la prioridad relativa de cada lead, mientras que el grupo aporta una caracterización de su perfil cuando existe información suficiente para asignarlo. De esta manera, la implementación proporciona dos elementos complementarios para la gestión comercial: la posición del prospecto dentro del orden de atención y el perfil al que pertenece.

Capítulo 9

Conclusiones

1. El análisis BPMN determinó que la priorización debe aplicarse a partir de la etapa “Interesado”, después del contacto y perfilamiento del lead.
2. El tratamiento diferenciado de la ausencia permitió conservar 49.1 % más leads y 10.0 % más conversiones que el criterio de casos completos.
3. La regresión logística concentró 4.15 veces más conversiones que la selección aleatoria al priorizar el 10.0 % de la cartera.
4. Las 1.6 millones de simulaciones de Monte Carlo demostraron que el modelo superó la selección aleatoria en todos los niveles de capacidad evaluados.
5. El modelo proporcionó un criterio cuantitativo y reproducible para determinar qué leads atender primero según su probabilidad estimada de conversión.

Capítulo 10

Recomendaciones

1. Validar prospectivamente el modelo con leads nuevos antes de adoptar sus resultados como criterio permanente de priorización. La evaluación realizada en este trabajo utilizó información histórica y demostró, mediante 1.6 millones de simulaciones de Monte Carlo, que el ordenamiento del modelo supera la selección aleatoria en todos los niveles de capacidad analizados. Sin embargo, una prueba prospectiva permitiría determinar si esta ventaja se mantiene cuando la priorización se utiliza dentro de la operación comercial. Se recomienda comparar durante un periodo definido los resultados obtenidos con el modelo frente a la gestión sin un mecanismo sistemático de priorización, utilizando indicadores como *lift*, conversiones concentradas y cantidad de leads atendidos por conversión.

2. Evaluar la capacidad de generalización del modelo con información de nuevos proyectos residenciales y, posteriormente, en otros contextos comerciales. El estudio se desarrolló con información histórica de seis proyectos de una misma empresa, por lo que la aplicabilidad de los patrones identificados fuera de esta población debe comprobarse empíricamente. Esta validación permitiría determinar qué relaciones se mantienen en nuevos desarrollos y cuáles dependen de las características particulares de los proyectos, las estrategias de captación o la población analizada.

3. Mejorar la trazabilidad de la información que se incorpora durante el recorrido del lead por el proceso comercial. El análisis mostró que varios campos se completan de manera progresiva y que su ausencia puede contener información relacionada con el avance del prospecto. Se recomienda registrar, cuando sea posible, el momento en que cada dato se incorpora al CRM y distinguir entre información aún no recopilada y campos que permanecen vacíos por problemas de registro. Esto permitiría estudiar con mayor precisión el efecto de la completitud y evitar que ambos tipos de ausencia sean tratados como una misma condición en modelos posteriores.

4. Ampliar el registro estructurado de las interacciones tempranas con los leads. Variables como la cantidad de intentos de contacto, el momento de cada interacción, el canal utilizado y el resultado obtenido podrían aportar información adicional antes de la etapa de priorización. Su incorporación en investigaciones posteriores permitiría evaluar si el comportamiento inicial del prospecto mejora la capacidad predictiva respecto de las variables disponibles en el presente estudio, siempre que estas señales puedan conocerse antes del desenlace comercial.

5. Monitorear el desempeño del modelo conforme se incorporen nuevos datos y cambien las condiciones de captación y comercialización. La información analizada abarca distintos proyectos y periodos, por lo que las relaciones aprendidas por el modelo pueden modificarse ante cambios en campañas, canales, perfiles de clientes o características del mercado. Se recomienda dar seguimiento a métricas como PR-AUC, Brier score y *lift* en los niveles de capacidad utilizados por el equipo comercial, y recalibrar o volver a entrenar el modelo cuando se observen cambios sostenidos en su desempeño.

6. Evaluar en estudios posteriores la utilidad comercial de los segmentos obtenidos mediante K-Means. La segmentación permitió identificar seis perfiles de leads a partir de sus características, pero su construcción fue descriptiva y no demuestra que estrategias comerciales diferenciadas produzcan mejores

resultados para cada grupo. Se recomienda utilizar estos segmentos como base para diseñar y evaluar pruebas controladas de mensajes, contenidos o formas de seguimiento, con el fin de determinar si la caracterización obtenida puede traducirse en diferencias observables en la respuesta comercial.

Referencias

Abbott, D. (2015). *Defining measures of success for predictive models.* Machine Learning Times. Descargado de `https://www.predictiveanalyticsworld.com/machinelearningtimes/defining-measures-of-success-for-predictive-models-0608152/5519/`

Ahearne, M., Hughes, D. E., y Schillewaert, N. (2007). Why sales reps should welcome information technology: Measuring the impact of CRM-based IT on sales effectiveness. *International Journal of Research in Marketing*, *24*(4), 336–349. doi: 10.1016/j.ijresmar.2007.09.003

Berry, M. J. A., y Linoff, G. S. (2004). *Data mining techniques: For marketing, sales, and customer relationship management* (2.ª ed.). Wiley.

Blattberg, R. C., Kim, B.-D., y Neslin, S. A. (2008). *Database marketing: Analyzing and managing customers.* Springer.

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. doi: 10.1023/A:1010933404324

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, *78*(1), 1–3. doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

Burez, J., y Van den Poel, D. (2009). Handling class imbalance in customer churn prediction. *Expert Systems with Applications*, *36*(3), 4626–4636. doi: 10.1016/j.eswa.2008.05.027

Bykowsky, E., Devignes, J.-C., Cruz, G., Valdivieso, M., y Torres, C. (2025). *How leaders can leverage AI for B2B sales.* McKinsey & Company. Descargado de `https://www.mckinsey.com/capabilities/growth-marketing-and-sales/our-insights/five-ways-b2b-sales-leaders-can-win-with-tech-and-ai`

Caliński, T., y Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, *3*(1), 1–27. doi: 10.1080/03610927408827101

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide* (Inf. Téc.). Chicago, IL: The CRISP-DM Consortium, SPSS Inc. Descargado de `https://api.semanticscholar.org/CorpusID:59777418`

Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. doi: 10.1613/jair.953

Chicco, D., y Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, *21*, 6. doi: 10.1186/s12864-019-6413-7

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, *20*(1), 37–46. doi: 10.1177/001316446002000104

Cramér, H. (1946). *Mathematical methods of statistics.* Princeton University Press.

Davies, D. L., y Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *PAMI-1*(2), 224–227. doi: 10.1109/TPAMI.1979.4766909

Davis, J., y Goadrich, M. (2006). The relationship between precision-recall and ROC curves. En *Proceedings of the 23rd international conference on machine learning* (pp. 233–240). doi: 10.1145/1143844.1143874

Devriendt, F., Moldovan, D., y Verbeke, W. (2018). A literature survey and experimental evaluation of the state-of-the-art in uplift modeling: A stepping stone toward the development of prescriptive analytics. *Big Data*, *6*(1), 13–41. doi: 10.1089/big.2017.0104

Drummond, C., y Holte, R. C. (2006). Cost curves: An improved method for visualizing classifier performance. *Machine Learning*, *65*(1), 95–130. doi: 10.1007/s10994-006-8199-5

Dumas, M., La Rosa, M., Mendling, J., y Reijers, H. A. (2018). *Fundamentals of business process management* (2.ª ed.). Springer. doi: 10.1007/978-3-662-56509-4

Elkan, C. (2001). The foundations of cost-sensitive learning. En *Proceedings of the 17th international joint conference on artificial intelligence* (pp. 973–978). Descargado de https://dl.acm.org/doi/10.5555/1642293.1642479

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, *27*(8), 861–874. doi: 10.1016/j.patrec.2005.10.010

Fernández, A., García, S., Galar, M., Prati, R. C., Krawczyk, B., y Herrera, F. (2018). *Learning from imbalanced data sets*. Springer. doi: 10.1007/978-3-319-98074-4

González-Flores, L., Rubiano-Moreno, J., y Sosa-Gómez, G. (2025). The relevance of lead prioritization: A B2B lead scoring model based on machine learning. *Frontiers in Artificial Intelligence*, *8*, 1554325. doi: 10.3389/frai.2025.1554325

Han, J., Kamber, M., y Pei, J. (2011). *Data mining: Concepts and techniques* (3.ª ed.). Morgan Kaufmann.

Hand, D. J. (2009). Measuring classifier performance: A coherent alternative to the area under the ROC curve. *Machine Learning*, *77*(1), 103–123. doi: 10.1007/s10994-009-5119-5

Hanley, J. A., y McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, *143*(1), 29–36. doi: 10.1148/radiology.143.1.7063747

Hashemi-Pour, C., y Sutner, S. (2024). *What is a business intelligence dashboard (BI dashboard)?* TechTarget. Descargado de https://www.techtarget.com/searchbusinessanalytics/definition/business-intelligence-dashboard

Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. doi: 10.1007/978-0-387-84858-7

Hosmer, D. W., Lemeshow, S., y Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley. doi: 10.1002/9781118548387

Hotz, N. (2018). *What is CRISP-DM?* Data Science PM. Descargado de https://example.invalid/fuente-retirada

IBM. (s.f.). *What is overfitting?* IBM Think Topics. Descargado de https://www.ibm.com/topics/overfitting (Consultado durante el desarrollo del trabajo – URL pendiente de verificación final)

James, G., Witten, D., Hastie, T., y Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2.ª ed.). Springer. doi: 10.1007/978-1-0716-1418-1

Kaufman, L., y Rousseeuw, P. J. (1990). *Finding groups in data: An introduction to cluster analysis*. Wiley. doi: 10.1002/9780470316801

Kuhn, M., y Johnson, K. (2013). *Applied predictive modeling*. Springer. doi: 10.1007/978-1-4614-6849-3

Ling, C. X., y Li, C. (1998). Data mining for direct marketing: Problems and solutions. En *Proceedings of the 4th international conference on knowledge discovery and data mining* (pp. 73–79).

Ling, C. X., y Sheng, V. S. (2010). Cost-sensitive learning and the class imbalance problem. En C. Sammut y G. I. Webb (Eds.), *Encyclopedia of machine learning* (pp. 231–235). Springer. doi: 10.1007/978-0-387-30164-8_197

Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, *28*(2), 129–137. doi: 10.1109/TIT.1982.1056489

Long Jr., L. (2023). *What is a sales funnel? complete guide and examples.* Salesforce. Descargado de https://www.salesforce.com/sales/funnel/

Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in neural information processing systems 30* (pp. 4765–4774). Descargado de https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. En *Proceedings of the fifth berkeley symposium on mathematical statistics and probability* (Vol. 1, pp. 281–297).

Matthews, B. W. (1975). Comparison of the predicted and observed secondary structure of T4 phage lysozyme. *Biochimica et Biophysica Acta (BBA) — Protein Structure*, *405*(2), 442–451. doi: 10.1016/0005-2795(75)90109-9

Miller, K. (2025). *What is a customer journey map? process, stages, and example.* Harvard Business School Online. Descargado de https://online.hbs.edu/blog/post/customer-journey-map

Moncrief, W. C., y Marshall, G. W. (2005). The evolution of the seven steps of selling. *Industrial Marketing Management*, *34*(1), 13–22. doi: 10.1016/j.indmarman.2004.06.001

Niculescu-Mizil, A., y Caruana, R. (2005). Predicting good probabilities with supervised learning. En *Proceedings of the 22nd international conference on machine learning* (pp. 625–632). doi: 10.1145/

1102351.1102430

Nygård, R., y Mezei, J. (2020). Automating lead scoring with machine learning: An experimental study. En *Proceedings of the 53rd hawaii international conference on system sciences.* doi: 10.24251/HICSS.2020.177

Object Management Group. (2011). *Business process model and notation (BPMN), version 2.0* (Inf. Téc. n.º formal/2011-01-03). Object Management Group. Descargado de `https://www.omg.org/spec/BPMN/2.0/PDF`

Ohiomah, A., Andreev, P., Benyoucef, M., y Hood, D. (2019). The role of lead management systems in inside sales performance. *Journal of Business Research*, *102*, 163–177. doi: 10.1016/j.jbusres.2019.05.018

Oldroyd, J. B., McElheran, K., y Elkington, D. (2011). The short life of online sales leads. *Harvard Business Review*, *89*(3), 100–103.

Palmer, T. (2025). *Bridging real estate and data science.* MIT Sloan. Descargado de `https://example.invalid/fuente-retirada`

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830. Descargado de `https://jmlr.org/papers/v12/pedregosa11a.html`

Piatetsky-Shapiro, G., y Masand, B. (1999). Estimating campaign benefits and modeling lift. En *Proceedings of the 5th acm sigkdd international conference on knowledge discovery and data mining* (pp. 185–193). doi: 10.1145/312129.312225

Provost, F., y Domingos, P. (2003). Tree induction for probability-based ranking. *Machine Learning*, *52*(3), 199–215. doi: 10.1023/A:1024099825458

Provost, F., y Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking.* O'Reilly Media.

Python Software Foundation. (s.f.). *What is Python? executive summary.* Descargado de `https://www.python.org/doc/essays/blurb/` (Consultado el 18 de abril de 2026)

Raychaudhuri, S. (2008). Introduction to Monte Carlo simulation. En *Proceedings of the 2008 winter simulation conference* (pp. 91–100). Descargado de `https://www.informs-sim.org/wsc08papers/012.pdf`

Riley, R. D., Archer, L., Snell, K. I. E., Ensor, J., Dhiman, P., Martin, G. P., ... Collins, G. S. (2024). Evaluation of clinical prediction models (part 2): How to undertake an external validation study. *BMJ*, *384*, e074820. doi: 10.1136/bmj-2023-074820

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, *20*, 53–65. doi: 10.1016/0377-0427(87)90125-7

Rubinstein, R. Y., y Kroese, D. P. (2016). *Simulation and the Monte Carlo method* (3.ª ed.). Wiley. doi: 10.1002/9781118631980

Sabnis, G., Chatterjee, S. C., Grewal, R., y Lilien, G. L. (2013). The sales lead black hole: On sales reps' follow-up of marketing leads. *Journal of Marketing*, *77*(1), 52–67. doi: 10.1509/jm.10.0047

Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, *10*(3), e0118432. doi: 10.1371/journal.pone.0118432

Salesforce. (2024). *Prospect vs. lead vs. sales opportunity: The differences.* Descargado de `https://www.salesforce.com/blog/prospect-vs-lead/`

Smith, A.-S., Stöber, J., y Ulrich, J. (2020). *How data analytics helps sales reps win more deals.* McKinsey & Company. Descargado de `https://example.invalid/fuente-retirada`

Tableau. (s.f.). *What is data visualization? definition, examples, and learning resources.* Descargado de `https://example.invalid/fuente-retirada` (Consultado el 18 de abril de 2026)

Tan, X., Lim, S., Lim, T., Tan, C. W., y Husaini, N. A. (2024). Leveraging random forest algorithm for enhanced lead conversion and customer retention. *International Journal on Advanced Science, Engineering and Information Technology*, *14*, 2141–2148. doi: 10.18517/ijaseit.14.6.11984

Tukey, J. W. (1949). Comparing individual means in the analysis of variance. *Biometrics*, *5*(2), 99–114. doi: 10.2307/3001913

Verbeke, W., Dejaeger, K., Martens, D., Hur, J., y Baesens, B. (2012). New insights into churn prediction in the telecommunication sector: A profit driven data mining approach. *European Journal of Operational Research*, *218*(1), 211–229. doi: 10.1016/j.ejor.2011.09.031

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, *22*(158), 209–212. doi: 10.1080/01621459.1927.10502953

Wu, M., Andreev, P., y Benyoucef, M. (2024). The state of lead scoring models and their impact on sales performance. *Information Technology & Management*, *25*, 69–98. doi: 10.1007/s10799-023-00388-w

Apéndice A

Modelo BPMN del proceso comercial

La Figura A.1 resume el proceso comercial documentado durante el levantamiento del flujo de trabajo. El diagrama muestra la interacción entre el asistente comercial, el sistema CRM y el asesor comercial desde el ingreso y la asignación del lead hasta la reserva del proyecto.

El detalle de los subprocesos que conforman este flujo se presenta en las Figuras 8.2 a 8.4 del capítulo de resultados.

Figura original omitida en la edición pública para proteger información comercial.

Figura A.1: Modelo BPMN completo del proceso comercial de gestión de leads

Fuente: elaboración propia.

Apéndice B

Diccionario de variables

El diccionario reúne las 62 variables que conformaron el conjunto de datos final. Para cada una se presenta el tipo de dato, una descripción, los valores o rangos observados y el porcentaje de datos faltantes, calculado sobre los 437,648 registros analizados. El Cuadro B.1 documenta así la estructura de la información utilizada en las distintas etapas del análisis.

Tabla B.1: Diccionario de variables del conjunto de datos final integrado

Nombre de columna	**Tipo**	**Descripción**	**Valores posibles / rango**	**% ausente**
`canal_de_anuencia`	Texto	Canal por el que el lead otorgó anuencia o fue captado formalmente. Puede diferir del canal de contacto.	Detalle de categorías omitido en la edición pública	0.4 %
`canal_de_contacto`	Texto	Canal por el que se realizó el primer contacto con el lead. La normalización se limitó a mayúsculas y minúsculas, errores tipográficos y separadores.	Detalle de categorías omitido en la edición pública	0.6 %
`estado_civil`	Texto	Estado civil declarado del lead. La categoría 'Solter@ + hijos' se unificó con 'Solter@' y la información sobre hijos se trasladó a tiene_hijos.	Detalle de categorías omitido en la edición pública	88.3 %
`fecha_creacion_trato`	Fecha (texto)	Fecha en que el trato fue creado en el CRM.	Detalle de categorías omitido en la edición pública	24.7 %
`ingreso_familiar`	Texto	Rango de ingreso familiar mensual en quetzales. Formato inconsistente (algunos con prefijo 'Q', otros sin él).	Detalle de categorías omitido en la edición pública	83.9 %
`lugar_trabajo`	Texto	Zona o municipio donde trabaja el lead.	Detalle de categorías omitido en la edición pública	89.6 %
`lugar_vivienda`	Texto	Zona o municipio de residencia actual del lead (texto libre).	Detalle de categorías omitido en la edición pública	88.5 %
`nucleo_familiar`	Texto	Número de personas en el núcleo familiar del lead.	Detalle de categorías omitido en la edición pública	91.4 %
`opciones_visitadas`	Texto	Proyectos de la competencia visitados previamente por el lead.	Detalle de categorías omitido en la edición pública	75.8 %
`participantes_en_credito`	Texto	Número de personas que participarían en el crédito hipotecario.	Detalle de categorías omitido en la edición pública	86.5 %

continúa en la siguiente página

Tabla B.1 – continuación de la página anterior

Nombre de columna	Tipo	Descripción	Valores posibles / rango	% ausente
proyecto	Texto	Proyecto inmobiliario de EmpresaAnonimizada de interés del lead.	Detalle de categorías omitido en la edición pública	0.0 %
razon_de_compra	Texto	Razón principal de compra declarada por el lead.	Detalle de categorías omitido en la edición pública	80.3 %
sector _referidor	Texto	Sector o tipo de referidor que presentó al lead. Clasificación interna del equipo comercial.	Detalle de categorías omitido en la edición pública	84.2 %
sexo	Texto	Sexo registrado del lead.	Detalle de categorías omitido en la edición pública	56.6 %
tipo_unidad	Texto	Tipo o tamaño de unidad de interés declarado por el lead.	Detalle de categorías omitido en la edición pública	70.6 %
apartamento_no _label	Texto	Número de unidad o apartamento asociado al trato. Proviene de columnas *_label de PT2 y de la columna homónima 'Unidad #' en las reexportaciones PT3.	Detalle de categorías omitido en la edición pública	99.2 %
apto_referidor _label	Texto	Número de apartamento del cliente que refirió al lead. Como no existe un equivalente inequívoco en las reexportaciones PT3, el campo se dejó vacío para esas filas para evitar mezclarlo con 'sector_referidor'.	Detalle de categorías omitido en la edición pública	99.9 %
bodega_asignada _label	Texto	Identificador de la bodega asignada al trato, cuando aplica.	Detalle de categorías omitido en la edición pública	99.2 %
campania	Texto	Nombre de la campaña de mercadeo que originó el lead. Se normalizaron textos duplicados, sufijos 'Copia', errores tipográficos y separadores.	Detalle de categorías omitido en la edición pública	22.6 %
cantidad _parqueos_label	Texto	Número de parqueos incluidos o solicitados en el trato.	Detalle de categorías omitido en la edición pública	99.2 %
csi _calificacion _amenidades _label	Decimal	Calificación de satisfacción del cliente (CSI, escala 1–5) sobre las amenidades del proyecto, recolectada en encuesta post-visita/post-venta.	Detalle de categorías omitido en la edición pública	98.7 %
csi _calificacion _apartamento _label	Decimal	Calificación de satisfacción del cliente (CSI, escala 1–5) sobre el apartamento, recolectada en encuesta post-visita/post-venta.	Detalle de categorías omitido en la edición pública	98.7 %
csi _calificacion _proyecto_label	Decimal	Calificación de satisfacción del cliente (CSI, escala 1–5) sobre el proyecto en general, recolectada en encuesta post-visita/post-venta.	Detalle de categorías omitido en la edición pública	98.7 %
csi_comentarios _adicionales _label	Texto	Comentario textual libre asociado a la encuesta de satisfacción del cliente (CSI).	Detalle de categorías omitido en la edición pública	98.8 %
csi _conocimiento _asesor_label	Decimal	Calificación de satisfacción del cliente (CSI, escala 1–5) sobre el conocimiento técnico del asesor comercial.	Detalle de categorías omitido en la edición pública	98.7 %

continúa en la siguiente página

Tabla B.1 – continuación de la página anterior

Nombre de columna	Tipo	Descripción	Valores posibles / rango	% ausente
csi_tiempo_seguimiento_label	Decimal	Calificación de satisfacción del cliente (CSI, escala 1–5) sobre el tiempo de seguimiento recibido.	Detalle de categorías omitido en la edición pública	98.7 %
cuota_deseada_label	Texto	Rango de cuota mensual deseada por el lead para el crédito hipotecario, en quetzales.	Detalle de categorías omitido en la edición pública	93.0 %
edad	Decimal	Edad declarada del lead en años. Los valores fuera del rango de 18 a 90 años se trataron como faltantes durante la limpieza base.	Detalle de categorías omitido en la edición pública	89.7 %
fuente_pt2	Texto	Nombre del proyecto de origen de la exportación armonizada (histórico de PT2, reutilizado también para identificar el proyecto de origen en las reexportaciones PT3).	Detalle de categorías omitido en la edición pública	0.0 %
id_trato	Entero	Identificador único del trato comercial en el CRM de EmpresaAnonimizada. Se utiliza como clave primaria del conjunto de datos.	Detalle de categorías omitido en la edición pública	0.0 %
ingreso_crm_label	Texto	Campo de ingreso registrado directamente en el CRM. Contiene valores numéricos y texto ('SI'/'NO'), por lo que requiere limpieza adicional antes de utilizarse con fines analíticos.	Detalle de categorías omitido en la edición pública	99.6 %
modelo_label	Texto	Modelo o tipología de unidad de interés o reservada (p. ej., '2 habitaciones', 'Bodega', 'Casa A').	Detalle de categorías omitido en la edición pública	99.2 %
nps_recomendacion_proyecto_label	Decimal	Puntaje de Net Promoter Score (NPS, escala 0–10) sobre la probabilidad de que el cliente recomiende el proyecto.	Detalle de categorías omitido en la edición pública	98.7 %
parqueo_1_label	Texto	Identificador del primer parqueo asignado al trato.	Detalle de categorías omitido en la edición pública	99.5 %
parqueo_2_label	Texto	Identificador del segundo parqueo asignado al trato (cuando el trato incluye más de uno).	Detalle de categorías omitido en la edición pública	99.4 %
parqueo_3_label	Texto	Identificador del tercer parqueo asignado al trato (cuando el trato incluye más de dos).	Detalle de categorías omitido en la edición pública	99.2 %
person_id	Decimal	Identificador numérico de la persona/prospecto en el CRM. Una persona puede tener múltiples tratos.	Detalle de categorías omitido en la edición pública	0.1 %
proyref_label	Texto	Proyecto de EmpresaAnonimizada en el que el referidor (cliente que refirió al lead) ya es o fue cliente.	Detalle de categorías omitido en la edición pública	99.5 %
razon_inversion_label	Texto	Razón de inversión declarada por el lead cuando 'razon_de_compra' = Inversión (p. ej., Renta, Venta o Renta/Venta).	Detalle de categorías omitido en la edición pública	99.6 %

continúa en la siguiente página

Tabla B.1 – continuación de la página anterior

Nombre de columna	Tipo	Descripción	Valores posibles / rango	% ausente
tiene_hijos	Texto	Indica si el lead declaró tener hijos. Se normalizó a partir de 52 variantes originales e incorpora la información trasladada desde estado_civil.	Detalle de categorías omitido en la edición pública	93.5 %
tipo_modelo _label	Texto	Variante constructiva del modelo de unidad (Convencional o Modificado).	Detalle de categorías omitido en la edición pública	99.3 %
tipovisita _label	Texto	Tipo de visita realizada al proyecto: Programada, Sorpresa o Inédita.	Detalle de categorías omitido en la edición pública	98.1 %
torre _referidora _label	Texto	Torre o unidad referidora asociada al trato, cuando el lead llegó por referencia de otro cliente.	Detalle de categorías omitido en la edición pública	92.6 %
ubicacion _bodega_label	Texto	Ubicación (sótano/nivel) de la bodega asignada al trato.	Detalle de categorías omitido en la edición pública	99.4 %
ubicacion _parqueos_label	Texto	Ubicación (sótano/nivel) de los parqueos asignados al trato.	Detalle de categorías omitido en la edición pública	99.6 %
user_id	Decimal	Identificador numérico del asesor comercial asignado al trato.	Detalle de categorías omitido en la edición pública	0.0 %
target_won	Entero	Variable objetivo binaria. 1 = el lead convirtió al alcanzar Reserva o una etapa posterior; 0 = no convirtió. Se construyó a partir de 'status' y 'Etapa Trato', variables excluidas del modelado por fuga de información.	Detalle de categorías omitido en la edición pública	0.0 %
proyecto_fuera _alcance	Entero	Indicador binario que identifica si el proyecto asociado al lead es proyecto01, proyecto04 o proyecto05, los proyectos de menor volumen en este conjunto de datos.	Detalle de categorías omitido en la edición pública	0.0 %
fuente_dataset	Texto	Variable de trazabilidad que identifica el origen del registro en el conjunto de datos integrado.	Detalle de categorías omitido en la edición pública	0.0 %
campania _plataforma	Texto	Plataforma de distribución inferida a partir del nombre de la campaña. 'portal_demo' corresponde al prefijo PortalAnonimizado; 'directo', a campañas propias de EmpresaAnonimizada; y 'otro', a eventos, corredores y otros canales.	Detalle de categorías omitido en la edición pública	22.6 %
campania_tipo	Texto	Tipo o formato publicitario de la campaña. Clasificado por prioridad decreciente: messenger > EmpresaAnonimizada > top > footer > inbox > fan_page > open_house > evento > segmentada > presupuesto_diario > whatsapp > principal > leads > cotizador > otro.	Detalle de categorías omitido en la edición pública	22.6 %

continúa en la siguiente página

Tabla B.1 – continuación de la página anterior

Nombre de columna	Tipo	Descripción	Valores posibles / rango	% ausente
campania_audiencia	Texto	Audiencia geográfica identificada a partir del nombre de la campaña. 'la' corresponde a Los Ángeles y se activa únicamente con 'USA LA' o 'EEUU LA'; 'eeuu' representa Estados Unidos en general y 'guatemala' es la categoría por defecto.	Detalle de categorías omitido en la edición pública	22.6 %
rango_edad_modelo	Texto	Rango de edad derivado de la columna 'edad' mediante los intervalos utilizados en el CRM original. La variable original 'Rango de Edad' se excluyó por su menor cobertura.	Detalle de categorías omitido en la edición pública	89.7 %
municipio_proyecto	Texto	Municipio donde se ubica el proyecto. Los proyectos incluidos en el análisis se encuentran en la Ciudad de Guatemala.	Detalle de categorías omitido en la edición pública	3.8 %
zona_proyecto	Decimal	Zona de la Ciudad de Guatemala donde se ubica el proyecto. Se incorporó como atributo geográfico del entorno.	Detalle de categorías omitido en la edición pública	3.8 %
subzona_proyecto	Texto	Subzona o colonia específica del proyecto. Complementa zona_proyecto con un mayor nivel de detalle geográfico.	Detalle de categorías omitido en la edición pública	5.2 %
m2_minimo	Decimal	Área mínima en m² de los productos disponibles en el proyecto (todas las torres, 2024).	Detalle de categorías omitido en la edición pública	3.8 %
m2_maximo	Decimal	Área máxima en m² de los productos disponibles en el proyecto (todas las torres, 2024).	Detalle de categorías omitido en la edición pública	3.8 %
precio_minimo	Decimal	Precio mínimo de lista del proyecto en USD (2024), agregado sobre todas las torres y tipos de unidad.	Detalle de categorías omitido en la edición pública	3.8 %
precio_maximo	Decimal	Precio máximo de lista del proyecto en USD (2024), agregado sobre todas las torres y tipos de unidad.	Detalle de categorías omitido en la edición pública	13.3 %
precio_m2_promedio	Decimal	Precio promedio por m² del proyecto en USD para 2024, calculado como valor representativo del proyecto completo.	Detalle de categorías omitido en la edición pública	3.8 %
precio_promedio	Decimal	Precio promedio por unidad en USD, agregado sobre todas las torres y tipos de unidad del proyecto (2024).	Detalle de categorías omitido en la edición pública	3.8 %

Nota sobre columnas redundantes. Las columnas `fuente_pt2` y `fuente_dataset` registran la misma información de trazabilidad del proyecto bajo nombres distintos. Ambas conservan variantes de capitalización y acentuación para un mismo proyecto; por ejemplo, “proyecto04” y “proyecto04” aparecen como categorías separadas.

Apéndice C

Embudo de completitud de una iteración previa de leads calificados

Este anexo conserva el embudo de completitud calculado en una iteración previa sobre un extracto de leads calificados.

Tabla C.1: Embudo de completitud de variables sobre el universo de leads calificados

Variable exigida de forma acumulada	Ausencia individual	N acumulado	Conversiones
fuente_pt2	–	45,614	870
canal_de_anuencia	0.1 %	45,589	862
canal_de_contacto	0.1 %	45,574	862
sexo	23.5 %	34,881	831
ingreso_familiar	38.0 %	27,006	750
razon_de_compra	38.7 %	23,994	741
estado_civil	44.8 %	21,891	734
edad	48.7 %	20,376	729
nucleo_familiar	53.4 %	17,180	716
tiene_hijos	61.3 %	15,200	672

Fuente: elaboración propia.

En ese extracto histórico, exigir simultáneamente las diez variables redujo el número de registros de 45,614 a 15,200 y mantuvo 672 de las 870 conversiones registradas.

Apéndice D

Detalle de la ingeniería de variables

A partir de la base depurada se generaron catorce columnas de enriquecimiento. Nueve incorporaron atributos de los proyectos residenciales obtenidos de fuentes externas e integrados mediante una tabla de referencia común: `municipio_proyecto`, `zona_proyecto`, `subzona_proyecto`, `m2_minimo`, `m2_maximo`, `precio_minimo`, `precio_maximo`, `precio_m2_promedio` y `precio_promedio`. Otras cuatro variables —`campania_plataforma`, `campania_tipo`, `campania_audiencia` y `rango_edad_modelo`— se derivaron de información ya disponible en el CRM. Finalmente, `fuente_dataset` registró la procedencia de cada fila para mantener su trazabilidad. En el proyecto para el que no se contó con una referencia externa equivalente, los atributos de superficie y precio se mantuvieron como valores faltantes.

Para representar los predictores del Universo H se generaron variables adicionales a partir de los campos disponibles en etapas tempranas del proceso comercial. Las categorías originales de `canal_de_anuencia` se agruparon en `canal_familia`, con siete categorías: *pauta_digital*, *portal*, *directo*, *referido*, *presencial*, *exterior* y *otro*. De esta variable se derivó `es_referido`, mientras que `es_inversion` se obtuvo de `razon_de_compra`. Los rangos de `ingreso_familiar` se transformaron en `ingreso_mid` mediante el punto medio de cada intervalo, y con la edad y el ingreso se construyeron `mayor_45` e `ingreso_alto`. También se generaron cuatro términos de interacción: `edad_x_ingreso`, `edad_x_inversion`, `edad_x_referido` e `ingreso_x_inversion`.

Una vez finalizada la preparación, se verificó que el conjunto destinado al modelado cumpliera las condiciones definidas para su uso: ausencia de valores faltantes, variable de respuesta binaria, identificadores de trato únicos y exclusión de variables con fuga de información. También se comprobó que los seis proyectos continuaran representados y que el enriquecimiento mantuviera las 437,648 observaciones. Las versiones con información posterior al desenlace se conservaron únicamente para auditoría y no se utilizaron en el entrenamiento. Las verificaciones no identificaron inconsistencias.

Apéndice E

Evidencia complementaria del análisis exploratorio

Este anexo reúne evidencia complementaria del análisis exploratorio presentado en la Sección 8.2.5 del capítulo de resultados.

E.1. Evolución temporal del volumen y de la conversión

La Figura E.1 muestra la evolución mensual del volumen de leads y de la tasa de conversión entre agosto de 2017 y abril de 2026. El volumen presenta incrementos en períodos en los que coinciden campañas de varios proyectos, mientras que la tasa de conversión se mantiene relativamente baja a lo largo de la serie. Dado que el patrón temporal observado estuvo más asociado con cambios en la intensidad de captación que con una separación consistente de la conversión, las variables temporales no se incorporaron al conjunto final de predictores.

Figura original omitida en la edición pública para proteger información comercial.

Figura E.1: Evolución temporal del volumen de leads y de la tasa de conversión comercial

Fuente: elaboración propia.

E.2. Campañas publicitarias con comportamiento atípico

El análisis de dispersión por campaña identificó trece casos atípicos dentro del conjunto analizado (Figura E.2). Uno corresponde al cotizador disponible en la página web de uno de los proyectos, que registró una tasa de conversión de 10.3 %, la más alta entre las campañas analizadas. Los doce casos restantes combinaron volúmenes altos de captación con tasas de conversión bajas o nulas. El caso más marcado fue una campaña asociada a un portal inmobiliario, con más de 20,000 leads y ninguna conversión registrada durante el período.

Figura original omitida en la edición pública para proteger información comercial.

Figura E.2: Dispersión de volumen de leads y tasa de conversión por campaña publicitaria

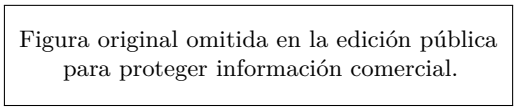
Fuente: elaboración propia.

La comparación confirma que el volumen de captación, por sí solo, no describe el desempeño comercial de una campaña. Por ello, el análisis de la Sección 8.2.5 considera conjuntamente volumen y tasa de conversión. Para el modelado, la información de campaña se representó mediante plataforma, tipo y audiencia; no se utilizó el nombre específico de la campaña debido a su elevada cardinalidad y a la limitada utilidad de esa identidad para generalizar a campañas futuras.

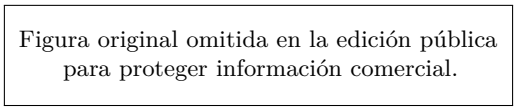
E.3. Diferencias demográficas de menor magnitud

E.3.1. Sexo

La captación se distribuyó de forma casi equitativa entre hombres y mujeres, con alrededor de 95,000 registros en cada grupo (Figura E.3a). Entre los leads que alcanzaron la reserva, en cambio, el 62 % correspondió a hombres y el 38 % a mujeres (Figura E.3b). Las tasas de conversión fueron de 2.33 % y 1.41 %, respectivamente.



(a) Distribución de leads captados por sexo



(b) Distribución porcentual de leads convertidos por sexo

Fuente: elaboración propia.

E.3.2. Estado civil y presencia de hijos

Entre los leads convertidos con estado civil registrado, las personas casadas representaron el 52.8 % (1,710 casos), las solteras el 44.0 % (1,426) y los futuros cónyuges el 3.2 % (103), como se observa en la Figura E.4. Estas proporciones describen la composición del grupo convertido, pero no permiten comparar por sí solas la propensión a convertir porque el volumen de leads difiere entre categorías. En la variable de hijos, la tasa de conversión fue de 10.4 % entre quienes declararon tenerlos y de 8.4 % entre quienes indicaron no tenerlos. La diferencia, de dos puntos porcentuales, fue menor que la observada entre los extremos de los rangos de edad.

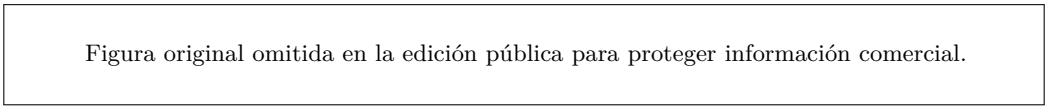


Figura E.4: Distribución de leads convertidos por estado civil registrado

Fuente: elaboración propia.

E.3.3. Tamaño del núcleo familiar

Los registros con información sobre el tamaño del núcleo familiar se concentraron en hogares de una y dos personas, con 12,260 y 15,606 casos, respectivamente (Figura E.5). Las categorías de mayor tamaño tuvieron una representación menor: 5,384 leads en núcleos de tres integrantes, 3,385 en los de cuatro y 795 en los de cinco o más. Esta distribución limita la comparación entre categorías y, dentro del análisis descriptivo, no se observó un patrón consistente de conversión asociado con el tamaño del hogar.

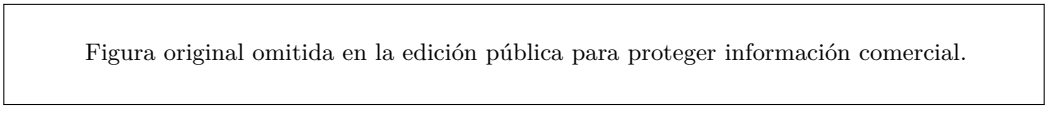


Figura E.5: Leads por tamaño del núcleo familiar, convertidos y no convertidos

Fuente: elaboración propia.

En el modelo final, ninguna de las variables descritas en esta sección presentó una importancia por permutación claramente distinta de cero (Sección 8.4.2).

Apéndice F

Registro de modelos evaluados

Este anexo registra las configuraciones evaluadas antes de seleccionar las dos especificaciones finales: la segmentación mediante K-Means (Sección 8.3.2) y el modelo predictivo de conversión (Sección 8.3).

En total se realizaron **812 ajustes**: **323** de segmentación, organizados en cuatro bloques de configuraciones, y **489** de modelado predictivo, distribuidos en diecisiete lotes. Para este registro, cada ajuste corresponde a una combinación distinta de variables, algoritmo y variante de entrenamiento, incluidos el universo de análisis, el tratamiento del desbalance y, cuando correspondía, los hiperparámetros.

F.1. Segmentación de leads (K-Means) — 323 modelos

Para el análisis de segmentación se evaluaron 37 conjuntos de variables mediante K-Means, con `n_init`=10 y una semilla fija. En cada caso se probaron distintos valores de k y se compararon mediante el coeficiente de silueta y los índices de Davies–Bouldin y Calinski–Harabasz. En conjunto, se realizaron 323 ajustes. El Cuadro F.1 presenta los cuatro bloques de variables considerados y la Figura F.1 muestra el coeficiente de silueta de la solución seleccionada para cada configuración.

Tabla F.1: Bloques de configuraciones de segmentación evaluadas

Bloque	**Conf.**	**Modelos**	**Qué se varió**	**Silueta (rango)**	**Resultado**
F2, E2, E3	3	27	Tamaño del conjunto de variables (13, 10 y 7), sobre el mismo universo	0.12 – 0.22	Separación baja; línea base del cuaderno.
A1–A14	14	126	Transformación numérica (log, cuantiles), tratamiento de atípicos, codificación categórica y PCA	0.27 – 0.86	Búsqueda metodológica más amplia; las siluetas más altas reproducían cruces de categorías.
D1–D10	10	90	Variables de perfil demográfico, de hogar, presencia de hijos, ingreso atenuado y edad discretizada	0.19 – 0.36	Ninguna alcanzó 0.50; la alta proporción de datos faltantes en las variables familiares limitó la separación.
R1–R10	10	80	Representación de la edad (continua frente a rangos) y variables de interacción categórica	0.35 – 0.54	**R1** ($k = 6$, edad continua ponderada a 0.25) fue la seleccionada: silueta 0.518 y seis segmentos, todos por encima del 12 % del universo.

Fuente: elaboración propia.

Figura original omitida en la edición pública para proteger información comercial.

Figura F.1: Coeficiente de silueta de la solución seleccionada para cada una de las 37 configuraciones de segmentación

Fuente: elaboración propia.

Criterios de descarte de las configuraciones con mayor silueta

Siete configuraciones alcanzaron un coeficiente de silueta superior al de R1 (0.518), pero ninguna cumplió simultáneamente los criterios definidos para la segmentación final. Las razones de descarte se agruparon en tres criterios.

Criterio de finalidad. La segmentación se planteó para caracterizar perfiles de cliente y apoyar la adaptación del argumento comercial (Sección 8.3.2). Por ello, se priorizaron atributos del lead, como edad, sexo, estado civil y razón de compra, sobre características propias del producto o del proyecto. Las configuraciones A7, A8 y A14 incorporan `precio_promedio` o `m2_minimo`, variables constantes dentro de cada proyecto. En consecuencia, una parte importante de la separación obtenida refleja el proyecto consultado y no diferencias adicionales entre perfiles de cliente. A7 y A8 también requieren `ingreso_familiar`, variable con cerca del 38 % de datos faltantes en el universo calificado.

Criterio de circularidad. Una silueta alta no se consideró evidencia suficiente de una segmentación útil cuando los grupos reproducían directamente las categorías de las variables utilizadas para construirlos. Este comportamiento fue especialmente claro en A10 ($k = 5$), basada únicamente en razón de compra y tipo de unidad: los segmentos correspondían a combinaciones de esas mismas variables. Aunque la configuración alcanzó una silueta de 0.86, no aportaba una estructura adicional que justificara su selección.

Un comportamiento similar se observó en A9, R6 y R7. En R6, la edad tuvo una influencia mínima y los grupos quedaron determinados principalmente por la razón de compra y el tipo de unidad. En R7, la interacción explícita entre estado civil y razón de compra generó segmentos estrechamente asociados con las categorías de esa misma interacción. Estas soluciones se descartaron porque la separación obtenida provenía principalmente de la definición de las variables de entrada y aportaba poca información adicional para caracterizar los perfiles.

Criterio de utilidad operativa. Las configuraciones con $k = 2$ (A8 y A14) generaron dos grupos demasiado amplios para diferenciar perfiles comerciales. En el otro extremo, R7 ($k = 9$) produjo un segmento con menos del 5 % del universo. Se favorecieron, por tanto, soluciones con un número de grupos suficiente para distinguir perfiles sin fragmentar en exceso la población.

Tabla F.2: Configuraciones con silueta superior a R1 y motivo de descarte

Config.	Silueta	k	Variables	Motivo de descarte
A10	0.86	5	razón de compra, tipo de unidad	Los segmentos reproducen combinaciones de las dos variables de entrada y no incorporan información adicional de edad.
A14	0.66	2	núcleo económico (7) por cuantiles	Solo genera dos grupos, definidos principalmente por el nivel de precio; razón de compra, sexo y estado civil presentan poca diferenciación.
A9	0.66	6	razón de compra, tipo de unidad, sexo	La separación depende principalmente de combinaciones de las categorías utilizadas como entrada.
A8	0.64	2	edad, ingreso, precio por cuantiles	Dos grupos definidos principalmente por el precio, con diferenciación limitada del perfil del lead.
A7	0.60	6	ingreso, precio promedio, m^2 mínimo	La separación refleja principalmente características del producto o proyecto; además, requiere información de ingreso.
R7	0.54	9	5 obligatorias + interacción civil–razón	Los segmentos reproducen las categorías de la interacción; uno de ellos concentra menos del 5 % del universo.
R6	0.54	4	5 obligatorias, edad con peso 0.1	La edad tiene una contribución mínima y la separación depende principalmente de razón de compra y tipo de unidad.

Fuente: elaboración propia.

Las configuraciones con silueta inferior a R1 tampoco aportaron una ventaja que compensara su menor separación. Las diez variantes demográficas (D1–D10) se ubicaron entre 0.19 y 0.36. Además, exigir `nucleo_familiar`, `participantes_en_credito` o `tiene_hijos` reducía el universo de análisis por la alta proporción de datos faltantes. Dentro de la familia R, las variantes que discretizaron la edad en rangos (R2 y R3) obtuvieron menor separación que R1, que utiliza la edad de forma continua. Las configuraciones R4, R5 y R8–R10 se mantuvieron por debajo de 0.50 sin generar perfiles suficientemente distintos. Las variantes exploratorias E1–E3 utilizaron variables de canal sobre universos más reducidos y quedaron fuera al definir el enfoque final de perfilamiento.

Dentro de las configuraciones evaluadas, las soluciones construidas únicamente con atributos del lead alcanzaron valores de silueta cercanos a 0.50. Los valores más altos se obtuvieron al incorporar atributos del producto o combinaciones categóricas que definían los grupos de forma casi directa, opciones que no respondían a la finalidad del análisis. R1 ($k = 6$, edad continua con peso 0.25 y silueta 0.518) ofreció el mejor equilibrio entre separación, interpretabilidad y utilidad comercial: generó seis perfiles, todos con más del 12 % del universo, sin incorporar variables de proyecto ni interacciones que determinaran los segmentos de forma casi predefinida.

F.2. Modelo predictivo de conversión — 489 modelos

Los 489 ajustes predictivos se distribuyeron en diecisiete lotes ejecutados en tres cuadernos y sus carpetas de resultados. A lo largo de estas iteraciones variaron el conjunto de variables, el universo de análisis, el algoritmo y el tratamiento del desbalance de clases. La comparación y selección final se realizó sobre la conversión, definida como la llegada del lead a Reserva o a una etapa posterior. El Cuadro F.3 resume los lotes, su tamaño y el aporte de cada uno a la decisión final.

Tabla F.3: Lotes de la búsqueda del modelo predictivo

Lote	**Modelos**	**Aporte a la decisión**
Grid F1–F7	208	Exploración inicial de conjuntos de variables, poblaciones, estrategias de sobremuestreo y algoritmos. Permitió identificar el aporte de las variables de canal y de los indicadores de ausencia, y mostró que el sobremuestreo no mejoraba de forma consistente el ordenamiento.
I1–I5 (perfil 100 % completo)	24	Cinco conjuntos anidados sobre el universo con mayor exigencia de completitud; funcionó como referencia para comparar el costo de excluir registros incompletos.
J1–J6 (universo de 13,038 leads)	33	Seis conjuntos anidados. Este lote produjo la mejor configuración previa a la auditoría; J6 se definió después de identificar riesgo de fuga de información en seis variables de J5.
A / B / C / E (objetivo de *recall*)	20	Cuatro conjuntos —variables del lead, indicadores de ausencia, variables de mayor aporte y una referencia con identidad de proyecto— evaluados con cuatro algoritmos. Al retirar las variables con fuga de información, el porcentaje de cartera necesario para alcanzar *recall* ≥ 0.70 pasó de 37 % a 64.2 %.
Universo H: LR frente a red neuronal	2	Comparación de la regresión logística final ($C = 0.55$, 24 variables) con un perceptrón multicapa sobre el mismo conjunto. La red neuronal no mejoró el PR-AUC y presentó una calibración menos favorable.
v1 — barrido de algoritmos	102	Seis conjuntos de variables evaluados con nueve algoritmos, además de cuatro estrategias de balanceo aplicadas a los conjuntos de mayor tamaño (Figura 8.10 del capítulo de resultados).
v2 — ajuste de hiperparámetros	18	Búsqueda aleatoria de 40 combinaciones internas sobre tres conjuntos de variables y seis algoritmos; de esta fase se obtuvo $C = 0.55$ para la regresión logística con regularización L2.
v3 — selección de variables	37	Incluyó 28 modelos univariados, ocho pasos de selección hacia adelante y una eliminación hacia atrás hasta un conjunto de once variables. Las tres estrategias coincidieron en el aporte de las variables de canal y de la interacción edad–ingreso.
v4 — ablación por familia	34	Evaluación de ocho familias de variables mediante análisis discriminante y *gradient boosting*; la familia de canal mostró el mayor aporte entre las comparadas.
v5 — candidatos finalistas	6	Comparación de los seis candidatos con mejor desempeño en las rondas anteriores, repetida con una segunda semilla (Figura F.2).
v6 — comparación de universos	4	Cuatro definiciones de completitud comparadas por tamaño, conversiones retenidas y costo operativo. Esta fase llevó a seleccionar el Universo H (Figura F.3); una variante adicional exploró una definición todavía menos restrictiva.
Total	**489**	

Fuente: elaboración propia.

La Figura 8.10 del capítulo de resultados presenta el PR-AUC obtenido en el barrido de algoritmos por conjunto de variables. El valor más alto (0.226) correspondió al análisis discriminante lineal en una

especificación que incluía la identidad del proyecto. Esa alternativa se descartó porque depender de la identidad del proyecto limita su aplicación a desarrollos sin historial previo (Sección 8.3.1). Entre las especificaciones que excluyeron esa variable, el análisis discriminante y la regresión logística obtuvieron los mejores resultados. La regresión logística se seleccionó por su desempeño y por la posibilidad de interpretar y auditar directamente sus predicciones.

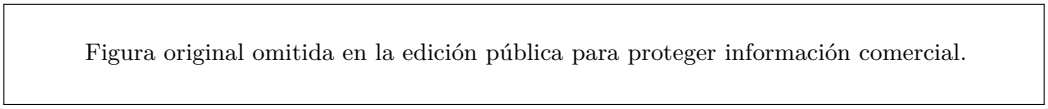


Figura F.2: Candidatos finalistas: PR-AUC frente a porcentaje de cartera para *recall* ≥ 0.70

Fuente: elaboración propia.

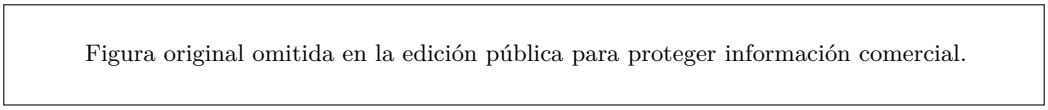


Figura F.3: Reconstrucción del universo de entrenamiento: tamaño, conversiones retenidas y costo operativo

Fuente: elaboración propia.

La comparación de universos mostró que exigir únicamente información de canal permitía conservar más registros, pero producía un ordenamiento menos favorable. En el otro extremo, aumentar los requisitos de completitud reducía el universo sin una mejora proporcional del desempeño. Entre las alternativas evaluadas, el Universo H —canal, edad, ingreso y fuente— presentó el mejor equilibrio entre cobertura de la población, conversiones retenidas y desempeño operativo.

El detalle de la comparación entre algoritmos sobre el conjunto base de variables y de las estrategias de tratamiento del desbalance se presenta en el Anexo G.

Apéndice G

Comparación entre algoritmos y estrategias de balanceo

La comparación de algoritmos siguió la matriz de diseño experimental descrita en la metodología. Se evaluaron seis conjuntos de variables predictoras, nueve algoritmos de clasificación supervisada y cinco estrategias de tratamiento del desbalance. Las comparaciones utilizaron validación cruzada estratificada de cinco pliegues y predicciones fuera de muestra.

G.1. Comparación entre algoritmos

El Cuadro G.1 presenta el mejor PR-AUC obtenido por cada algoritmo en el barrido v1 sobre *P2_Clean*, un conjunto de 18 variables de perfil y canal que excluye las variables con riesgo de fuga de información y la identidad del proyecto. La comparación se realizó mediante validación cruzada de cinco pliegues sobre el universo de casos completos utilizado en esa etapa (13,038 leads).

Tabla G.1: Mejor PR-AUC por algoritmo sobre el conjunto base *P2_Clean* (barrido v1)

Algoritmo	**PR-AUC**
Análisis discriminante lineal	0.216
Regresión logística (L2)	0.204
Gradient boosting	0.200
Random forest	0.192
Hist. gradient boosting	0.189
Regresión logística (L1)	0.162
Extra trees	0.155
AdaBoost	0.141
Naive Bayes	0.050

Fuente: elaboración propia.

Valores tomados de `results_v1_grid.csv` (`qualified_run/exploracion/`).

Un perceptrón multicapa entrenado adicionalmente sobre el Universo H obtuvo un PR-AUC equivalente o inferior al de la regresión logística y una calibración menos favorable de las probabilidades estimadas. Además, su estructura no ofrece una ecuación directa para auditar predicciones individuales, a diferencia de la regresión logística.

G.2. Estrategias de tratamiento del desbalance

Ninguna de las cinco estrategias evaluadas mejoró de forma consistente el desempeño de la regresión logística. El sobremuestreo sintético modificó el PR-AUC entre 0.002 y 0.005 respecto del modelo sin balancear,

pero el cambio no mantuvo una dirección consistente entre configuraciones. El submuestreo aleatorio redujo el PR-AUC en aproximadamente 0.02; este patrón es consistente con la pérdida de información que supone descartar observaciones de la clase mayoritaria. Dado que el objetivo del modelo es ordenar los leads según su probabilidad estimada de conversión, la especificación final se mantuvo sin remuestreo.

Apéndice H

Caracterización detallada de la segmentación

Este anexo presenta la configuración, las métricas de calidad y la composición de los seis segmentos obtenidos con el modelo final de agrupamiento. La validación externa de estos perfiles se discute en la Sección 8.3.2.

H.1. Configuración y calidad interna

La configuración final representa cada lead mediante la edad estandarizada, con un peso de 0.25, y cuatro variables categóricas: sexo, estado civil, razón de compra y tipo de unidad. Estas últimas se codificaron mediante *one-hot encoding*, con ajustes de ponderación para evitar que una variable dominara únicamente por su número de categorías. La solución seleccionada utiliza $k = 6$. El universo de trabajo (Universo S) contiene 20,647 observaciones y 731 conversiones, equivalentes a una tasa de 3.54 %. El Cuadro 8.6 contextualiza este universo respecto de la base consolidada completa.

Tabla H.1: Métricas de calidad del modelo de segmentación final ($k = 6$)

Indicador	**Valor**
Observaciones	20,647
Número de clústeres (k)	6
Coeficiente de silueta	0.517
Índice de Davies–Bouldin	0.908
Índice de Calinski–Harabasz	13,121

Fuente: elaboración propia.

H.2. Representación visual de los segmentos

La proyección sobre los dos primeros componentes principales de la matriz de segmentación (Figura 8.11 del capítulo de resultados) conserva en conjunto el 59.4 % de la varianza: 32.4 % en el primer componente y 27.0 % en el segundo. Esta reducción se utilizó únicamente para visualizar la solución. El K-Means se ajustó sobre las trece dimensiones de la matriz completa y no sobre los dos componentes representados en la figura.

En la proyección, los seis grupos muestran una separación visual consistente con el coeficiente de silueta obtenido. El patrón en bandas se explica por la codificación de variables categóricas, que produce un número limitado de combinaciones posibles en la representación. En los dos segmentos de inversión, que incluyen hombres y mujeres, el centroide se ubica entre los subgrupos definidos por sexo. En los otros cuatro segmentos, esta variable es más homogénea y el centroide coincide de forma más cercana con la zona de mayor concentración de observaciones.

H.3. Poder discriminante de las variables

Las cinco variables originales presentaron diferencias estadísticamente significativas entre segmentos ($p < 0.001$ en todos los casos). Según el tamaño de efecto (Figura H.1), `razon_de_compra` fue la variable con mayor capacidad de diferenciación (V de Cramér = 1.00), seguida de `sexo` (0.855), `estado_civil` (0.713), `edad` ($\eta^2 = 0.151$) y `tipo_unidad` (0.144).

Figura original omitida en la edición pública para proteger información comercial.

Figura H.1: Poder discriminante de las variables en la segmentación final

Fuente: elaboración propia.

Figura original omitida en la edición pública para proteger información comercial.

Figura H.2: Perfil estandarizado de los seis segmentos del modelo final

Fuente: elaboración propia.

H.4. Tamaño y composición de los segmentos

Ningún segmento concentró una proporción residual del universo (Figura H.3). El menor representa el 12.4 % de los leads y el mayor el 21.0 %; el tamaño medio es de 3,441 observaciones. Esta distribución evita grupos excesivamente pequeños y facilita su interpretación como perfiles para el uso comercial previsto.

Figura original omitida en la edición pública para proteger información comercial.

Figura H.3: Distribución de tamaños de los seis segmentos del modelo final

Fuente: elaboración propia.

Tabla H.2: Perfil de los seis segmentos del modelo final

Seg.	Nombre	N	%	Edad	Razón	Est. civil	Sexo
0	Compradora independiente	3,562	17.3	35.1	Vivienda	Solter@	F
1	Inversionista consolidado	3,379	16.4	44.7	Inversión	Casad@	M
2	Compradora residencial consolidada	2,798	13.6	41.8	Vivienda	Casad@	F
3	Comprador familiar de mayor espacio	4,339	21.0	42.7	Vivienda	Casad@	M
4	Comprador joven de vivienda	4,004	19.4	33.9	Vivienda	Solter@	M
5	Inversionista emergente	2,565	12.4	36.4	Inversión	Solter@	M

Fuente: elaboración propia.

Figura original omitida en la edición pública para proteger información comercial.

Figura H.4: Composición de cada segmento según las cuatro variables categóricas de perfilamiento

Fuente: elaboración propia.

La Figura H.4 muestra cómo se distribuyen las variables de perfil dentro de cada segmento. La razón de compra establece la primera diferencia: los segmentos 1 y 5 están integrados por leads que declaran inversión, mientras que los segmentos 0, 2, 3 y 4 corresponden a vivienda. Dentro de estos grupos, el sexo y el estado civil aportan una diferenciación adicional. Los segmentos 0 y 2 son femeninos y los segmentos 3 y 4 masculinos; los dos perfiles de inversión incluyen ambos sexos, con una proporción de hombres entre 64 % y 67 %. A su vez, los segmentos 0, 4 y 5 concentran entre 89 % y 98 % de personas solteras, mientras que los segmentos 1, 2 y 3 superan el 99 % de personas casadas. El tipo de unidad presenta menor diferenciación: en los seis segmentos predominan las unidades de dos y tres habitaciones, en concordancia con el menor tamaño de efecto observado para esta variable.

Apéndice I

Coeficientes principales del modelo predictivo final

El modelo predictivo final corresponde a una regresión logística con regularización L2. Para cada lead, la probabilidad estimada de conversión se calcula mediante:

$$P(\text{conversión}) = \frac{1}{1 + e^{-z}}, \tag{I.1}$$

donde z corresponde a la combinación del intercepto y los coeficientes asociados a las variables activas para cada observación. El Cuadro I.1 presenta los términos con coeficientes de magnitud absoluta superior a 0.60 para documentar los componentes de mayor magnitud dentro de la ecuación final.

Tabla I.1: Coeficientes del modelo final con magnitud absoluta superior a 0.60

Término	**Coeficiente**
Intercepto (β_0)	−1.9577
`canal_de_anuencia = Referencia`	−1.9124
`canal_de_contacto` (categorías agrupadas)	+1.8356
`opciones_visitadas = _missing_`	−1.5828
`participantes_en_credito = _missing_`	−1.2080
`campania_tipo = footer`	+0.9628
`estado_civil = _missing_`	−0.9310
`razon_de_compra = _missing_`	−0.8512
`canal_de_contacto = Visita Inédita`	−0.8307
`tipo_unidad = 2 Habs`	−0.8253
`canal_de_anuencia` (categorías agrupadas)	+0.8039
`lugar_vivienda = _missing_`	−0.7769
`tipo_unidad` (categorías agrupadas)	+0.7742
`campania_tipo = inbox`	+0.7465
`lugar_trabajo = Zona 6`	+0.6915
`campania_audiencia = guatemala`	−0.6861
`canal_de_contacto = Fanpage Líderes`	−0.6674
`campania_tipo = presupuesto_diario`	−0.6614
`lugar_vivienda = Departamentos Norte`	+0.6539
`canal_de_anuencia = Actividad Posicionamiento`	−0.6504
`canal_de_anuencia = Actividades MKT`	+0.6392
`canal_de_contacto = WhatsApp`	−0.6299
`canal_de_contacto = Referencia`	+0.6209

Fuente: elaboración propia.

Nota sobre la interpretación. El signo de cada coeficiente indica la dirección de su asociación con la probabilidad estimada de conversión, manteniendo constantes los demás términos y tomando como

comparación la categoría de referencia correspondiente. La magnitud de estos coeficientes no constituye, por sí sola, un ordenamiento de importancia ni implica una relación causal. Las variables categóricas se codificaron mediante *one-hot encoding*; las categorías con menos de 30 observaciones se agruparon en una categoría residual, identificada en el cuadro como "categorías agrupadas".

Apéndice J

Material operativo omitido en la edición pública

Las guías con capturas, la trazabilidad operativa y los anexos con código o documentación de la empresa se omiten por confidencialidad. La implementación pública adaptada se documenta en el repositorio.